

无约束优化问题

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法
- 4 线搜索一般收敛性分析
- 5 梯度下降法
- 6 Barzilar-Borwein 方法
- 7 应用举例

无约束优化问题

- 问题描述: $\text{minimize } f(x)$
- $f(x)$ 为凸函数, 且二次可微。
- 无约束问题求解的两种方法:
- 求解梯度方程:

$$\nabla f(x^*) = 0$$

- 迭代逼近:

$$f(x^{(k)}) \rightarrow p^*$$

例如:

- 二次优化:

$$\text{minimize } \frac{1}{2}x^T Px + q^T x + r, P \in S_+^n$$

梯度方程

$$Px^* + q = 0$$

初始点和下水平集

初始点和下水平集

- 起始点 $x^{(0)}$ 满足：
 1. $x^{(0)} \in \text{dom } f$;
 2. $S = \{x \in \text{dom } f \mid f(x) \leq f(x^{(0)})\}$ 为闭集。
- 满足条件2的几种函数：
 - 函数 $f(x)$ 任意下水平集都是闭集；
 - 函数的定义域为 R^n
 - 当 $x \rightarrow \text{bd dom } f$ 时， $f(x) \rightarrow \infty$

例子

二次优化问题

$$\text{minimize } (1/2)x^T Px + q^T x + r,$$

其中 $P \in \mathbf{S}_+^n$, $q \in \mathbf{R}^n$, $r \in \mathbf{R}$. 该问题可以通过一组线性方程描述的最优性条件 $Px^* + q = 0$ 求解. 当 $P \succ 0$, 存在唯一解, $x^* = -P^{-1}q$. 更一般情况下, P 不是正定矩阵, 此时如果 $Px^* = -q$ 有界, 任何解都是优化问题的最优解; 如果 $Px^* = -q$ 无解, 优化问题无下界(见习题9.1).

二次优化的一个特例是最小二乘问题

$$\text{minimize } \|Ax - b\|_2^2 = x^T (A^T A) x - 2 (A^T b)^T x + b^T b.$$

最优性条件

$$A^T A x^* = A^T b$$

称为最小二乘问题的正规方程.

例子

无约束几何规划问题

$$\text{minimize } f(x) = \log \left(\sum_{i=1}^m \exp(a_i^T x + b_i) \right).$$

最优性条件为

$$\nabla f(x^*) = \frac{1}{\sum_{j=1}^m \exp(a_j^T x^* + b_j)} \sum_{i=1}^m \exp(a_i^T x^* + b_i) a_i = 0,$$

一般情况该方程没有解析解,因此需要采用迭代算法. 对于该问题, 由于 $\text{dom } f = \mathbf{R}^n$, 任何点都可以作为初始点 $x^{(0)}$.

例子

线性不等式的解析中心

考虑优化问题

$$\text{minimize } f(x) = - \sum_{i=1}^m \log(b_i - a_i^T x),$$

其中函数 f 的定义域是开集

$$\text{dom } f = \{x \mid a_i^T x < b_i, i = 1, \dots, m\}.$$

问题的目标函数 f 叫做不等式 $a_i^T x \leq b_i$ 的对数障碍. 如果该问题存在, 他就是相对应不等式的解析中心. 此问题初始点 $x^{(0)}$ 必须满足严格不等式 $a_i^T x^{(0)} < b_i, i = 1, \dots, m$. 由于 f 是闭的, 任何点的下水平集 S 也是闭的。

强凸性

定义

定义 函数 $f(x)$ 在 S 上具有强凸性, 若 $f(x)$ 满足
$$\nabla^2 f(x) \succcurlyeq mI, m > 0$$

- 若函数 $f(x)$ 具有强凸性, 则有

$$\begin{aligned} f(y) &\geq f(x) + \nabla f(x)^T (y - x) + \frac{m}{2} \|y - x\|_2^2 \\ &\geq f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2 \end{aligned}$$

- p^* 为最优值, 则

$$f(x) - p^* \leq \frac{1}{2m} \|\nabla f(x)\|_2^2$$

强凸性及其含义

定义

定义 函数 $f(x)$ 在 S 上具有强凸性, 若 $f(x)$ 满足

$$\nabla^2 f(x) \succeq mI, m > 0$$

强凸性假设可得到如果有意义结果. For $x, y \in S$, 我们有

$$f(y) = f(x) + \nabla f(x)^T(y - x) + \frac{1}{2}(y - x)^T \nabla^2 f(z)(y - x)$$

其中 z 属于线段 $[x, y]$. 利用强凸性假设, 上式右边最后一项不会小于 $(m/2)\|y - x\|_2^2$, 因此不等式

$$f(y) \geq f(x) + \nabla f(x)^T(y - x) + \frac{m}{2}\|y - x\|_2^2$$

对任意 x 和 y 成立. 当 $m = 0$, 上式便会描述凸性的基本不等式;
当 $m > 0$, 对 $f(y)$ 的下界我们可以得到比单独利用凸性更好的结果。

强凸性及其含义

$f(x) - p^*$, which is the suboptimality of the point x , in terms of $\|\nabla f(x)\|_2$. The righthand side of (9.8) is a convex quadratic function of y (for fixed x). Setting the gradient with respect to y equal to zero, we find that $\tilde{y} = x - (1/m)\nabla f(x)$ minimizes the righthand side. Therefore we have

$$\begin{aligned} f(y) &\geq f(x) + \nabla f(x)^T(y - x) + \frac{m}{2}\|y - x\|_2^2 \quad (9.8) \\ &\geq f(x) + \nabla f(x)^T(\tilde{y} - x) + \frac{m}{2}\|\tilde{y} - x\|_2^2 \\ &= f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2. \end{aligned}$$

Since this holds for any $y \in S$, we have

$$p^* \geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2. \quad (9.9)$$

This inequality shows that if the gradient is small at a point, then the point is nearly optimal. The inequality (9.9) can also be interpreted as a condition for suboptimality which generalizes the optimality condition $\nabla f(x^*) = 0$.

强凸性及其含义

$f(x) - p^*$, which is the suboptimality of the point x , in terms of $\|\nabla f(x)\|_2$. The righthand side of (9.8) is a convex quadratic function of y (for fixed x). Setting the gradient with respect to y equal to zero, we find that $\tilde{y} = x - (1/m)\nabla f(x)$ minimizes the righthand side. Therefore we have

$$\begin{aligned} f(y) &\geq f(x) + \nabla f(x)^T(y - x) + \frac{m}{2}\|y - x\|_2^2 \\ &\geq f(x) + \nabla f(x)^T(\tilde{y} - x) + \frac{m}{2}\|\tilde{y} - x\|_2^2 \\ &= f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2. \end{aligned}$$

Since this holds for any $y \in S$, we have

$$p^* \geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2. \quad (9.9)$$

This inequality shows that if the gradient is small at a point, then the point is nearly optimal. The inequality (9.9) can also be interpreted as a condition for suboptimality which generalizes the optimality condition $\nabla f(x^*) = 0$:

强凸性及其含义

由 $p^* \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|_2^2$. (9.9) 可得

到, $\|\nabla f(x)\|_2 \leq (2m\epsilon)^{1/2} \implies f(x) - p^* \leq \epsilon$. We can also derive a bound on $\|x - x^*\|_2$, the distance between x and any optimal point x^* , in terms of $\|\nabla f(x)\|_2$:

$$\|x - x^*\|_2 \leq \frac{2}{m} \|\nabla f(x)\|_2. \quad 9.11$$

To see this, we apply (9.8) with $y = x^*$ to obtain

$$\begin{aligned} p^* = f(x^*) &\geq f(x) + \nabla f(x)^T (x^* - x) + \frac{m}{2} \|x^* - x\|_2^2 \\ &\geq f(x) - \|\nabla f(x)\|_2 \|x^* - x\|_2 + \frac{m}{2} \|x^* - x\|_2^2, \end{aligned}$$

where we use the Cauchy-Schwarz inequality in the second inequality. Since $p^* \leq f(x)$, we must have

$$-\|\nabla f(x)\|_2 \|x^* - x\|_2 + \frac{m}{2} \|x^* - x\|_2^2 \leq 0,$$

from which (9.11) follows. One consequence of (9.11) is that the optimal point x^* is unique.

强凸性

The inequality (9.8) implies that the sublevel sets contained in S are bounded, so in particular, S is bounded. Therefore the maximum eigenvalue of $\nabla^2 f(x)$, which is a continuous function of x on S , is bounded above on S , i.e., there exists a constant M such that

$$\nabla^2 f(x) \preceq MI$$

- 对于 $x \in S$, 矩阵 $\nabla^2 f(x) \in S_{++}^n$ 的特征值从大到小依次为 $\{\lambda_1, \dots, \lambda_n\}$ 。则有:

$$mI \prec= \lambda_n I \prec= \nabla^2 f(x) \prec= \lambda_1 I \prec= MI$$

定义

定义 矩阵 $\nabla^2 f(x) \in S_{++}^n$ 的条件数为最大特征值与最小特征值之比, 即 $r = \lambda_1 / \lambda_n$ 。

- 条件数的上界:

$$r \leq M/m$$

提纲

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法
- 4 线搜索一般收敛性分析
- 5 梯度下降法
- 6 Barzilar-Borwein 方法
- 7 应用举例

引言: 无约束可微优化算法

$$\min_{x \in \mathbb{R}^n} f(x).$$

- 线搜索: $x^{k+1} = x^k + \alpha_k d^k$

- ① 先确定下降方向: 负梯度、牛顿方向、拟牛顿方向等.

- ② 按某种准则搜索步长.

- 信赖域: $z^k = x^k + d^k$

$$d^k = \arg \min_d (g^k)^\top d + d^\top B d, \text{ s.t. } \|d\|_2 \leq \Delta_k$$

- ① 给定信赖域半径(步长) Δ_k , 构造信赖域子问题求解方向 d^k .

- ② 如果 z^k 满足下降性条件, 则 $x^{k+1} = z^k$. 否则 $x^{k+1} = x^k$. 更新 Δ_k .

线搜索算法: 盲人下山

- 求解 $f(x)$ 的最小值点如同盲人下山, 无法一眼望知谷底, 而是:
 - ① 首先确定下一步该向哪一方向行走.
 - ② 再确定沿着该方向行走多远后停下以便选取下一个下山方向.
- 线搜索类算法的数学表述:

$$x^{k+1} = x^k + \alpha_k d^k.$$

我们称 d^k 为迭代点 x^k 处的搜索方向, α_k 为相应的步长. 这里要求 d^k 是一个下降方向, 即 $(d^k)^T \nabla f(x^k) < 0$.

- 线搜索类算法的关键是如何选取一个好的方向 $d^k \in \mathbb{R}^n$ 以及合适的步长 α_k .

α_k 的选取: 精确线搜索算法

- 选取 d^k 的方法千差万别, 但选取 α_k 的方法却非常相似.
- 首先构造一元辅助函数

$$\phi(\alpha) = f(x^k + \alpha d^k),$$

其中 d^k 是给定的下降方向, $\alpha > 0$ 是该辅助函数的自变量.

- 线搜索的目标是选取合适的 α_k 使得 $\phi(\alpha_k)$ 尽可能减小. 这要求:
 - ① α_k 应该使得 f 充分下降
 - ② 不应在寻找 α_k 上花费过多的计算量
- 一个自然的想法是寻找 α_k 使得

$$\alpha_k = \operatorname{argmin}_{\alpha > 0} \phi(\alpha),$$

即 α_k 为最佳步长. 这种线搜索算法被称为精确线搜索算法

- 选取 α_k 通常需要很大计算量, 在实际应用中较少使用

α_k 的选取: 非精确线搜索算法

- 不要求 α_k 是 $\phi(\alpha)$ 的最小值点, 仅要求 $\phi(\alpha_k)$ 满足某些不等式. 这种线搜索方法被称为非精确线搜索算法.
- 选取 α_k 需要满足的要求被称为线搜索准则
- 线搜索准则的合适与否直接决定了算法的收敛性, 若选取不合适的线搜索准则将会导致算法无法收敛
- 例如, 若只要求选取的步长满足迭代点处函数值单调下降, 则函数值 $f(x^k)$ 的下降量可能不够充分, 导致算法无法收敛到极小值点

例子: 不合适的线搜索准则导致无法收敛

考虑一维无约束优化问题

$$\min_x f(x) = x^2,$$

迭代初始点 $x^0 = 1$. 由于问题是一维的, 下降方向只有 $\{-1, +1\}$ 两种. 我们选取 $d^k = -\text{sign}(x^k)$, 且只要求选取的步长满足迭代点处函数值单调下降, 即 $f(x^k + \alpha_k d^k) < f(x^k)$. 考虑选取如下两种步长:

$$\alpha_{k,1} = \frac{1}{3^{k+1}}, \quad \alpha_{k,2} = 1 + \frac{2}{3^{k+1}},$$

通过简单计算可以得到

$$x_1^k = \frac{1}{2} \left(1 + \frac{1}{3^k} \right), \quad x_2^k = \frac{(-1)^k}{2} \left(1 + \frac{1}{3^k} \right).$$

显然, 序列 $\{f(x_1^k)\}$ 和序列 $\{f(x_2^k)\}$ 均单调下降, 但序列 $\{x_1^k\}$ 收敛的点不是极小值点, 序列 $\{x_2^k\}$ 则在原点左右振荡, 不存在极限

非精确线搜索: Armijo 准则

定义 (Armijo 准则)

设 d^k 是点 x^k 处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k,$$

则称步长 α 满足 **Armijo** 准则, 其中 $c_1 \in (0, 1)$ 是一个常数.




Figure: Armijo 准则

Armijo 准则: 评注

- 引入Armijo 准则的目的是保证每一步迭代充分下降
- Armijo 准则有直观的几何含义, 它指的是点 $(\alpha, \phi(\alpha))$ 必须在直线

$$l(\alpha) = \phi(0) + c_1 \alpha \nabla f(x^k)^T d^k$$

的下方, 上图中区间 $[0, \alpha_1]$ 中的点均满足Armijo 准则

- 参数 c_1 通常选为一个很小的正数, 例如 $c_1 = 10^{-3}$, Armijo 准则非常容易得到满足
- Armijo 准则需要配合其他准则以保证迭代的收敛性, 因为 $\alpha = 0$ 显然满足Armijo 准则, 此时迭代序列中的点固定不变

回退法:以Armijo准则为例

- 给定初值 $\hat{\alpha}$, 回退法通过不断以指数方式缩小试探步长, 找到第一个满足Armijo 准则的点
- 回退法选取

$$\alpha_k = \gamma^{j_0} \hat{\alpha},$$

其中

$$j_0 = \min\{j = 0, 1, \dots \mid f(x^k + \gamma^j \hat{\alpha} d^k) \leq f(x^k) + c_1 \gamma^j \hat{\alpha} \nabla f(x^k)^T d^k\},$$

参数 $\gamma \in (0, 1)$ 为一个给定的实数

Algorithm 线搜索回退法

- 1: 选择初始步长 $\hat{\alpha}$, 参数 $\gamma, c \in (0, 1)$. 初始化 $\alpha \leftarrow \hat{\alpha}$.
 - 2: **while** $f(x^k + \alpha d^k) > f(x^k) + c\alpha \nabla f(x^k)^T d^k$ **do**
 - 3: 令 $\alpha \leftarrow \gamma\alpha$.
 - 4: **end while**
 - 5: 输出 $\alpha_k = \alpha$.
-

回退法:以Armijo准则为例

- 该算法被称为回退法是因为 α 的试验值是由大至小的,它可以确保输出的 α_k 能尽量地大
- 算法??不会无限进行下去,因为 d^k 是一个下降方向,当 α 充分小时,Armijo 准则总是成立的
- 实际应用中我们通常也会给 α 设置一个下界,防止步长过小

Goldstein 准则

- 为了克服Armijo 准则的缺陷, 我们需要引入其他准则来保证每一步的 α^k 不会太小
- Armijo准则只要求点 $(\alpha, \phi(\alpha))$ 必须处在某直线下方, 我们也可使用相同的形式使得该点必须处在另一条直线的上方. 这就是Armijo-Goldstein 准则, 简称Goldstein 准则

定义 (Goldstein 准则)

设 d^k 是点 x^k 处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c\alpha \nabla f(x^k)^T d^k, \quad (1a)$$

$$f(x^k + \alpha d^k) \geq f(x^k) + (1 - c)\alpha \nabla f(x^k)^T d^k, \quad (1b)$$

则称步长 α 满足**Goldstein** 准则, 其中 $c \in (0, \frac{1}{2})$.

Goldstein 准则

Goldstein 准则有直观的几何含义, 它指的是点 $(\alpha, \phi(\alpha))$ 必须在两条直线

$$l_1(\alpha) = \phi(0) + c\alpha \nabla f(x^k)^T d^k,$$

$$l_2(\alpha) = \phi(0) + (1 - c)\alpha \nabla f(x^k)^T d^k$$

之间. 区间 $[\alpha_1, \alpha_2]$ 中的点均满足 Goldstein 准则. 同时我们也注意到 Goldstein 准则确实去掉了过小的 α .




Figure: Goldstein 准则

Wolfe 准则

- Goldstein 准则: 设 d^k 是点 x^k 处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c\alpha \nabla f(x^k)^T d^k, \quad (2a)$$

$$f(x^k + \alpha d^k) \geq f(x^k) + (1 - c)\alpha \nabla f(x^k)^T d^k, \quad (2b)$$

则称步长 α 满足 **Goldstein** 准则, 其中 $c \in (0, \frac{1}{2})$.

- Wolfe 准则: 设 d^k 是点 x^k 处的下降方向, 若

$$f(x^k + \alpha d^k) \leq f(x^k) + c_1 \alpha \nabla f(x^k)^T d^k, \quad (3a)$$

$$\nabla f(x^k + \alpha d^k)^T d^k \geq c_2 \nabla f(x^k)^T d^k, \quad (3b)$$

则称步长 α 满足 **Wolfe** 准则, 其中 $c_1, c_2 \in (0, 1)$ 为给定的常数且 $c_1 < c_2$.

Wolfe 准则

- $\nabla f(x^k + \alpha d^k)^T d^k$ 恰好就是 $\phi(\alpha)$ 的导数, Wolfe 准则实际要求 $\phi(\alpha)$ 在点 α 处切线的斜率不能小于 $\phi'(0)$ 的 c_2 倍
- $\phi(\alpha)$ 的极小值点 α^* 处有 $\phi'(\alpha^*) = \nabla f(x^k + \alpha^* d^k)^T d^k = 0$, 因此 α^* 永远满足条件二. 而选择较小的 c_1 可使得 α^* 同时满足条件一, 即 Wolfe 准则在绝大多数情况下会包含线搜索子问题的精确解




Figure: Wolfe 准则

非单调线搜索准则

Armijo准则, Goldstein准则和Wolfe准则共同点: 使用他们产生的迭代点列都是单调的。但在实际应用中, 非单调算法有时会有更好的效果。需要应用非单调线搜索准备, 例如[Grippo]和[Zhang, Hager]。

定义 (Grippo)

设 d^k 是点 x^k 处的下降方向, $M > 0$ 为给定的正整数. 以下不等式可作为一种线搜索准则:

$$f(x^k + \alpha d^k) \leq \max_{0 \leq j \leq \min\{k, M\}} f(x^{k-j}) + c_1 \alpha \nabla f(x^k)^T d^k,$$

其中 $c_1 \in (0, 1)$ 为给定的常数.

- 该准则和Armijo 准则非常相似, 区别在于Armijo 准则要求下一次迭代的函数值 $f(x^{k+1})$ 相对于本次迭代的函数值 $f(x^k)$ 有充分下降, 而该准则只需要下一步函数值相比前面至多 M 步以内迭代的函数值有下降就可以了
- 这一准则的要求比Armijo 准则更宽, 它也不要求 $f(x^k)$ 的单调性

非单调线搜索准则

另一种非单调线搜索准则的定义更加宽泛.

定义 (Zhang, Hager)

设 d^k 是点 x^k 处的下降方向, $M > 0$ 为给定的正整数. 以下不等式可作为一种线搜索准则:

$$f(x^k + \alpha d^k) \leq C^k + c_1 \alpha \nabla f(x^k)^T d^k,$$

其中 C^k 满足递推式 $C^0 = f(x^0)$, $C^{k+1} = \frac{1}{Q^{k+1}}(\eta Q^k C^k + f(x^{k+1}))$, 序列 $\{Q^k\}$ 满足 $Q^0 = 1$, $Q^{k+1} = \eta Q^k + 1$, 参数 $\eta, c_1 \in (0, 1)$.

- 变量 C^k 实际上是本次搜索准则的参照函数值, 即充分下降性质的起始标准
- 下一步的标准 C^{k+1} 则是函数值 $f(x^{k+1})$ 和 C^k 的凸组合, 并非仅仅依赖于 $f(x^{k+1})$, 而凸组合的两个系数由参数 η 决定
- 当 $\eta = 0$ 时, 此准则就是Armijo 准则

提纲

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法**
- 4 线搜索一般收敛性分析
- 5 梯度下降法
- 6 Barzilar-Borwein 方法
- 7 应用举例

回退法的优缺点

- 只要修改一下算法的终止条件,回退法就可以被用在其他线搜索准则之上,它是最常用的线搜索算法之一.
- 然而,回退法的缺点也很明显:
 - ❶ 它无法保证找到满足Wolfe 准则的步长,即条件二不一定成立,但对一些优化算法而言,找到满足Wolfe 准则的步长是十分必要的
 - ❷ 回退法以指数的方式缩小步长,因此对初值 $\hat{\alpha}$ 和参数 γ 的选取比较敏感,当 γ 过大时每一步试探步长改变量很小,此时回退法效率比较低,当 γ 过小时回退法过于激进,导致最终找到的步长太小,错过了选取大步长的机会

基于多项式插值的线搜索算法

- 设初始步长 $\hat{\alpha}_0$ 已给定, 如果经过验证, $\hat{\alpha}_0$ 不满足Armijo 准则, 下一步就需要减小试探步长
- 基于 $\phi(0)$, $\phi'(0)$, $\phi(\hat{\alpha}_0)$ 这三个信息构造一个二次插值函数 $p_2(\alpha)$
- 寻找二次函数 $p_2(\alpha)$ 满足

$$p_2(0) = \phi(0), \quad p_2'(0) = \phi'(0), \quad p_2(\hat{\alpha}_0) = \phi(\hat{\alpha}_0).$$

由于二次函数只有三个参数, 以上三个条件可以唯一决定 $p_2(\alpha)$

- $p_2(\alpha)$ 的最小值点恰好位于 $(0, \hat{\alpha}_0)$ 内
- 取 $p_2(\alpha)$ 的最小值点 $\hat{\alpha}_1$ 作为下一个试探点, 利用同样的方式不断递归下去直至找到满足Armijo 准则的点
- 基于插值的线搜索算法可以有效减少试探次数, 但仍然不能保证找到的步长满足Wolfe 准则

提纲

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法
- 4 线搜索一般收敛性分析**
- 5 梯度下降法
- 6 Barzilar-Borwein 方法
- 7 应用举例

Zoutendijk定理

定理 (Zoutendijk定理)

考虑一般的迭代格式 $x^{k+1} = x^k + \alpha_k d^k$, 其中 d^k 是搜索方向, α_k 是步长, 且在迭代过程中 **Wolfe** 准则满足. 假设目标函数 f 下有界、连续可微且梯度 L -利普希茨连续, 即

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad \forall x, y \in \mathbb{R}^n,$$

那么

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x^k)\|^2 < +\infty,$$

其中 $\cos \theta_k$ 为负梯度 $-\nabla f(x^k)$ 和下降方向 d^k 夹角的余弦, 即

$$\cos \theta_k = \frac{-\nabla f(x^k)^T d^k}{\|\nabla f(x^k)\| \|d^k\|}.$$

这个不等式也被称为 **Zoutendijk** 条件.

Zoutendijk定理的证明

- 由Wolfe准则知 $\nabla f(x^{k+1})^T d^k \geq c_2 \nabla f(x^k)^T d^k$, 故

$$(\nabla f(x^{k+1}) - \nabla f(x^k))^T d^k \geq (c_2 - 1) \nabla f(x^k)^T d^k.$$

- 由柯西不等式和梯度 L -利普希茨连续性质,

$$(\nabla f(x^{k+1}) - \nabla f(x^k))^T d^k \leq \|\nabla f(x^{k+1}) - \nabla f(x^k)\| \|d^k\| \leq \alpha_k L \|d^k\|^2.$$

- 结合上述两式可得

$$\alpha_k \geq \frac{c_2 - 1}{L} \frac{\nabla f(x^k)^T d^k}{\|d^k\|^2}.$$

- 由Wolfe准则的条件一知 $f(x^{k+1}) \leq f(x^k) + c_1 \alpha_k \nabla f(x^k)^T d^k$, 注意到 $\nabla f(x^k)^T d^k < 0$, 将上式代入得

$$f(x^{k+1}) \leq f(x^k) + c_1 \frac{c_2 - 1}{L} \frac{(\nabla f(x^k)^T d^k)^2}{\|d^k\|^2}.$$

Zoutendijk定理的证明

- 根据 θ_k 的定义, 此不等式可等价表述为

$$f(x^{k+1}) \leq f(x^k) + c_1 \frac{c_2 - 1}{L} \cos^2 \theta_k \|\nabla f(x^k)\|^2.$$

- 再关于 k 求和, 我们有

$$f(x^{k+1}) \leq f(x^0) - c_1 \frac{1 - c_2}{L} \sum_{j=0}^k \cos^2 \theta_j \|\nabla f(x^j)\|^2.$$

- 又因为函数 f 是下有界的, 且由 $0 < c_1 < c_2 < 1$ 可知 $c_1(1 - c_2) > 0$, 因此当 $k \rightarrow \infty$ 时,

$$\sum_{j=0}^{\infty} \cos^2 \theta_j \|\nabla f(x^j)\|^2 < +\infty.$$

线搜索算法的收敛性

Zoutendijk 定理刻画了线搜索准则的性质, 配合下降方向 d^k 的选取方式我们可以得到最基本的收敛性.

推论 (线搜索算法的收敛性)

对于迭代法 $x^{k+1} = x^k + \alpha_k d^k$, 设 θ_k 为每一步负梯度 $-\nabla f(x^k)$ 与下降方向 d^k 的夹角, 并假设对任意的 k , 存在常数 $\gamma > 0$, 使得

$$\theta_k < \frac{\pi}{2} - \gamma,$$

则在 Zoutendijk 定理成立的条件下, 有

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0.$$

线搜索算法收敛性的证明

- 假设结论不成立, 即存在子列 $\{k_l\}$ 和正常数 $\delta > 0$, 使得

$$\|\nabla f(x^{k_l})\| \geq \delta, \quad l = 1, 2, \dots.$$

- 根据 θ_k 的假设, 对任意的 k ,

$$\cos \theta_k > \sin \gamma > 0.$$

- 我们仅考虑Zoutendijk条件中第 k_l 项的和, 有

$$\begin{aligned} \sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f(x^k)\|^2 &\geq \sum_{l=1}^{\infty} \cos^2 \theta_{k_l} \|\nabla f(x^{k_l})\|^2 \\ &\geq \sum_{l=1}^{\infty} (\sin^2 \gamma) \cdot \delta^2 \rightarrow +\infty, \end{aligned}$$

- 这显然和Zoutendijk定理矛盾. 因此必有

$$\lim_{k \rightarrow \infty} \|\nabla f(x^k)\| = 0.$$

收敛性分析:评注

- 线搜索算法收敛性建立在Zoutendijk条件之上, 它的本质要求是 $\theta_k < \frac{\pi}{2} - \gamma$, 即每一步的下降方向 d^k 和负梯度方向不能趋于正交.
- 几何直观: 当下降方向 d^k 和梯度正交时, 根据泰勒展开的一阶近似, 目标函数值 $f(x^k)$ 几乎不发生改变. 因此我们要求 d^k 与梯度正交方向夹角有一致的下界.
- 不涉及算法收敛速度的分析, 因为算法收敛速度极大地取决于 d^k 的选取.

提纲

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法
- 4 线搜索一般收敛性分析
- 5 梯度下降法**
- 6 Barzilar-Borwein 方法
- 7 应用举例

梯度下降法

- 对于光滑函数 $f(x)$, 在迭代点 x^k 处, 我们需要选择一个较为合理的 d^k 作为下降方向.
- 注意到 $\phi(\alpha) = f(x^k + \alpha d^k)$ 有泰勒展开

$$\phi(\alpha) = f(x^k) + \alpha \nabla f(x^k)^T d^k + \mathcal{O}(\alpha^2 \|d^k\|^2).$$

- 由柯西不等式, 当 α 足够小时取 $d^k = -\nabla f(x^k)$ 会使函数下降最快.
- 因此梯度法就是选取 $d^k = -\nabla f(x^k)$ 的算法, 它的迭代格式为

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k).$$

步长 α_k 的选取可依赖于线搜索算法, 也可直接选取固定的 α_k .

二次函数的梯度法

设二次函数 $f(x, y) = x^2 + 10y^2$, 初始点 (x^0, y^0) 取为 $(10, 1)$, 取固定步长 $\alpha_k = 0.085$. 我们使用梯度法 $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$ 进行15次迭代.




Figure: 梯度法的前15次迭代

二次函数的收敛定理

定理 (二次函数的收敛定理)

考虑正定二次函数

$$f(x) = \frac{1}{2}x^T A x - b^T x,$$

其最优值点为 x^* . 若使用梯度法 $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$ 并选取 α_k 为精确线搜索步长, 即

$$\alpha_k = \frac{\|\nabla f(x^k)\|^2}{\nabla f(x^k)^T A \nabla f(x^k)},$$

则梯度法关于迭代点列 $\{x^k\}$ 是Q-线性收敛的, 即

$$\|x^{k+1} - x^*\|_A^2 \leq \left(\frac{\lambda_1 - \lambda_n}{\lambda_1 + \lambda_n} \right)^2 \|x^k - x^*\|_A^2,$$

其中 λ_1, λ_n 分别为 A 的最大、最小特征值, $\|x\|_A \stackrel{\text{def}}{=} \sqrt{x^T A x}$ 为由正定矩阵 A 诱导的范数.

二次函数的收敛定理

- 定理中线性收敛速度的常数和矩阵 A 最大特征值与最小特征值之比有关.
- 从等高线角度来看, 这个比例越大则 $f(x)$ 的等高线越扁平, 迭代路径折返频率会随之变高, 梯度法收敛也就越慢.
- 这个结果其实说明了梯度法的一个很重大的缺陷: 当目标函数的海瑟矩阵条件数较大时, 它的收敛速度会非常缓慢.

梯度利普希茨连续

接下来分析当 $f(x)$ 为梯度利普希茨连续的凸函数时，梯度法的收敛性质。

定义 (梯度利普希茨连续)

给定可微函数 f ，若存在 $L > 0$ ，对任意的 $x, y \in \text{dom}f$ 有

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|, \quad (4)$$

则称 f 是梯度利普希茨连续的，相应利普希茨常数为 L 。有时也简记为梯度 L -利普希茨连续或 L -光滑。

引理 (二次上界)

设可微函数 $f(x)$ 的定义域 $\text{dom}f = \mathbb{R}^n$ ，且为梯度 L -利普希茨连续的，则函数 $f(x)$ 有二次上界：

$$f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2}\|y - x\|^2, \quad \forall x, y \in \text{dom}f. \quad (5)$$

可以证明:

$$\begin{aligned} & f(y) - f(x) - \nabla f(x)^T(y - x) \\ &= \int_0^1 (\nabla f(x + t(y - x)) - \nabla f(x))^T(y - x) dt \\ &\leq \int_0^1 \|\nabla f(x + t(y - x)) - \nabla f(x)\| \|y - x\| dt \\ &\leq \int_0^1 L \|y - x\|^2 t dt = \frac{L}{2} \|y - x\|^2, \end{aligned}$$

其中最后一行的不等式利用了梯度利普希茨连续的条件(??). 整理可得(??) 式成立.

梯度法在凸函数上的收敛性

定理 (梯度法在凸函数上的收敛性)

设函数 $f(x)$ 为凸的梯度 L -利普希茨连续函数, $f^* = f(x^*) = \inf_x f(x)$ 存在且可达. 如果步长 α_k 取为常数 α 且满足 $0 < \alpha < \frac{1}{L}$, 那么由迭代 $x^{k+1} = x^k + \alpha_k d^k$ 得到的点列 $\{x^k\}$ 的函数值收敛到最优值, 且在函数值的意义下收敛速度为 $\mathcal{O}(\frac{1}{k})$.

结论: 点列 $\{x^k\}$ 的函数值收敛到最优值, 且在函数值的意义下收敛速度为 $\mathcal{O}(\frac{1}{k})$.

如果函数 f 还是 m -强凸函数, 则梯度法的收敛速度会进一步提升为 Q -线性收敛.

证明

- 因为函数 f 是利普希茨可微函数, 对任意的 x , 根据二次上界引理,

$$f(x - \alpha \nabla f(x)) \leq f(x) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x)\|^2.$$

- 记 $\tilde{x} = x - \alpha \nabla f(x)$ 并限制 $0 < \alpha < \frac{1}{L}$, 我们有

$$\begin{aligned} f(\tilde{x}) &\leq f(x) - \frac{\alpha}{2} \|\nabla f(x)\|^2 \\ &\leq f^* + \nabla f(x)^T (x - x^*) - \frac{\alpha}{2} \|\nabla f(x)\|^2 \\ &= f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|x - x^* - \alpha \nabla f(x)\|^2) \\ &= f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|\tilde{x} - x^*\|^2), \end{aligned}$$

其中第一个不等式是因为 $0 < \alpha < \frac{1}{L}$, 第二个不等式为 f 的凸性, 第三个等式将右边第二项展开消除 $\|x - x^*\|^2$, 可知与第二个不等式相等.

- 在上式中取 $x = x^{i-1}, \tilde{x} = x^i$ 并将不等式对 $i = 1, 2, \dots, k$ 求和得到

$$\begin{aligned}\sum_{i=1}^k (f(x^i) - f^*) &\leq \frac{1}{2\alpha} \sum_{i=1}^k (\|x^{i-1} - x^*\|^2 - \|x^i - x^*\|^2) \\ &= \frac{1}{2\alpha} (\|x^0 - x^*\|^2 - \|x^k - x^*\|^2) \\ &\leq \frac{1}{2\alpha} \|x^0 - x^*\|^2.\end{aligned}$$

- 由二次上界($f(x - \alpha \nabla f(x)) \leq f(x) - \alpha (1 - \frac{L\alpha}{2}) \|\nabla f(x)\|^2$), 可知 $f(x^i)$ 是非增的, 所以

$$f(x^k) - f^* \leq \frac{1}{k} \sum_{i=1}^k (f(x^i) - f^*) \leq \frac{1}{2k\alpha} \|x^0 - x^*\|^2.$$

凸函数性质

当函数 f 还是 m -强凸函数,则梯度法的收敛速度会进一步提升为 Q -线性收敛。在给出收敛定理之前,需要如下引理来揭示凸的梯度 L -利普希茨连续函数的另一个重要性质。

引理

设函数 $f(x)$ 是 \mathbb{R}^n 上的凸可微函数,则以下结论等价:

- 1 f 的梯度为 L -利普希茨连续的;
- 2 函数 $g(x) \stackrel{\text{def}}{=} \frac{L}{2}x^T x - f(x)$ 是凸函数;
- 3 $\nabla f(x)$ 有余强制性,即对任意的 $x, y \in \mathbb{R}^n$, 有

$$(\nabla f(x) - \nabla f(y))^T(x - y) \geq \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|^2.$$

(1) \implies (2) 即证 $g(x)$ 的单调性. 对任意 $x, y \in \mathbb{R}^n$,

$$\begin{aligned} (\nabla g(x) - \nabla g(y))^T(x - y) &= L\|x - y\|^2 - (\nabla f(x) - \nabla f(y))^T(x - y) \\ &\geq L\|x - y\|^2 - \|x - y\| \|\nabla f(x) - \nabla f(y)\| \geq 0. \end{aligned}$$

因此 $g(x)$ 为凸函数.

凸函数性质

引理 (梯度 L -利普希茨函数的性质 (P33: 推论2.1))

设可微函数 $f(x)$ 的定义域为 \mathbb{R}^n 且存在一个全局极小点 x^* , 若 $f(x)$ 为梯度 L -利普希茨连续的, 则对任意的 x 有

$$\frac{1}{2L} \|\nabla f(x)\|^2 \leq f(x) - f(x^*).$$

(2) \implies (3)

- 构造辅助函数

$$f_x(z) = f(z) - \nabla f(x)^T z,$$

$$f_y(z) = f(z) - \nabla f(y)^T z,$$

容易验证 f_x 和 f_y 均为凸函数.

- $g_x(z) = \frac{L}{2} z^T z - f_x(z)$ 关于 z 是凸函数. 根据凸函数的性质, 我们有

$$g_x(z_2) \geq g_x(z_1) + \nabla g_x(z_1)^T (z_2 - z_1), \quad \forall z_1, z_2 \in \mathbb{R}^n.$$

整理可推出 $f_x(z)$ 有二次上界, 且对应的系数也为 L .

凸函数性质

- 注意到 $\nabla f_x(x) = 0$, 这说明 x 是 $f_x(z)$ 的最小值点. 由上页引理,

$$\begin{aligned} f_x(y) - f_x(x) &= f(y) - f(x) - \nabla f(x)^T(y - x) \\ &\geq \frac{1}{2L} \|\nabla f_x(y)\|^2 = \frac{1}{2L} \|\nabla f(y) - \nabla f(x)\|^2. \end{aligned}$$

- 同理, 对 $f_y(z)$ 进行类似的分析可得

$$f(x) - f(y) - \nabla f(y)^T(x - y) \geq \frac{1}{2L} \|\nabla f(y) - \nabla f(x)\|^2.$$

将以上两式不等号左右分别相加, 可得余强制性.

(3) \implies (1) 由余强制性和柯西不等式,

$$\begin{aligned} \frac{1}{L} \|\nabla f(x) - \nabla f(y)\|^2 &\leq (\nabla f(x) - \nabla f(y))^T(x - y) \\ &\leq \|\nabla f(x) - \nabla f(y)\| \|x - y\|, \end{aligned}$$

整理后即可得到 $f(x)$ 是梯度 L -利普希茨连续的.

梯度法在强凸函数上的收敛性

定理 (梯度法在强凸函数上的收敛性)

设函数 $f(x)$ 为 m -强凸的梯度 L -利普希茨连续函数, $f(x^*) = \inf_x f(x)$ 存在且可达. 如果步长 α 满足 $0 < \alpha < \frac{2}{m+L}$, 那么由梯度下降法迭代得到的点列 $\{x^k\}$ 收敛到 x^* , 且为 Q -线性收敛.

- 首先根据 f 强凸且 ∇f 利普希茨连续, 可得

$$g(x) = f(x) - \frac{m}{2}x^T x$$

为凸函数且 $\frac{L-m}{2}x^T x - g(x)$ 为凸函数.

- 由引理知函数 $g(x)$ 是梯度 $(L-m)$ -利普希茨连续的. 再次利用引理可得关于 $g(x)$ 的余强制性

$$(\nabla g(x) - \nabla g(y))^T(x - y) \geq \frac{1}{L-m} \|\nabla g(x) - \nabla g(y)\|^2.$$

梯度法在强凸函数上的收敛性

- 代入 $g(x)$ 的表达式, 可得

$$(\nabla f(x) - \nabla f(y))^T(x - y) \geq \frac{mL}{m+L} \|x - y\|^2 + \frac{1}{m+L} \|\nabla f(x) - \nabla f(y)\|^2.$$

- 再估计固定步长下梯度法的收敛速度. 设步长 $\alpha \in \left(0, \frac{2}{m+L}\right)$, 对 x^k, x^* 应用上式并注意到 $\nabla f(x^*) = 0$ 得

$$\begin{aligned} \|x^{k+1} - x^*\|_2^2 &= \|x^k - \alpha \nabla f(x^k) - x^*\|^2 \\ &= \|x^k - x^*\|^2 - 2\alpha \nabla f(x^k)^T(x^k - x^*) + \alpha^2 \|\nabla f(x^k)\|^2 \\ &\leq \left(1 - \alpha \frac{2mL}{m+L}\right) \|x^k - x^*\|^2 + \alpha \left(\alpha - \frac{2}{m+L}\right) \|\nabla f(x^k)\|^2 \\ &\leq \left(1 - \alpha \frac{2mL}{m+L}\right) \|x^k - x^*\|^2 \end{aligned}$$

$$\Rightarrow \|x^k - x^*\|^2 \leq c^k \|x^0 - x^*\|^2, \quad c = 1 - \alpha \frac{2mL}{m+L} < 1.$$

函数值收敛

强凸函数假设下

- 迭代点列 $\{x^k\}$ Q-线性收敛
- 如果取 $t = \frac{2}{m+L}$, 则有 $c = \frac{(\gamma-1)^2}{(\gamma+1)}$ 且 $\gamma = L/m$

如果 $\text{dom } f = \mathbf{R}^n$ 且 f 有极小点 x^* , 则

$$\frac{1}{2L} \|\nabla f(x)\|_2^2 \leq f(x) - f(x^*) \leq \frac{L}{2} \|x - x^*\|_2^2 \quad \forall x$$

因此:

$$f(x^k) - f^* \leq \frac{L}{2} \|x^k - x^*\|_2^2 \leq \frac{c^k L}{2} \|x^0 - x^*\|_2^2$$

函数值的估计: 达到 $f(x^k) - f^* \leq \epsilon$ 的迭代步数是 $O(\log(1/\epsilon))$

提纲

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法
- 4 线搜索一般收敛性分析
- 5 梯度下降法
- 6 Barzilar-Borwein 方法**
- 7 应用举例

Barzilar-Borwein 方法

- Barzilar-Borwein (BB) 方法是一种特殊的梯度法, 经常比一般的梯度法有着更好的效果.
- BB 方法的下降方向仍是点 x^k 处的负梯度方向 $-\nabla f(x^k)$, 但步长 α_k 并不是直接由线搜索算法给出的.
- 考虑梯度下降法的格式:

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k) \iff x^{k+1} = x^k - D^k \nabla f(x^k),$$

其中 $D^k = \alpha_k I$.

- BB 方法选取的 α_k 是如下两个最优问题之一的解:

$$\begin{aligned} \min_{\alpha} \quad & \|\alpha y^{k-1} - s^{k-1}\|^2, \\ \min_{\alpha} \quad & \|y^{k-1} - \alpha^{-1} s^{k-1}\|^2, \end{aligned}$$

其中引入记号 $s^{k-1} \stackrel{\text{def}}{=} x^k - x^{k-1}$ 以及 $y^{k-1} \stackrel{\text{def}}{=} \nabla f(x^k) - \nabla f(x^{k-1})$.

Barzilar-Borwein 方法

- 容易验证问题的解分别为

$$\alpha_{\text{BB1}}^k \stackrel{\text{def}}{=} \frac{(s^{k-1})^T y^{k-1}}{(y^{k-1})^T y^{k-1}} \quad \text{和} \quad \alpha_{\text{BB2}}^k \stackrel{\text{def}}{=} \frac{(s^{k-1})^T s^{k-1}}{(s^{k-1})^T y^{k-1}},$$

- 因此可以得到BB方法的两种迭代格式:

$$x^{k+1} = x^k - \alpha_{\text{BB1}}^k \nabla f(x^k) \quad \text{和} \quad x^{k+1} = x^k - \alpha_{\text{BB2}}^k \nabla f(x^k).$$

- 计算两种BB步长的任何一种仅仅需要函数相邻两步的梯度信息和迭代点信息, 不需要任何线搜索算法即可选取算法步长.
- BB方法计算出的步长可能过大或过小, 因此我们还需要将步长做上界和下界的截断, 即选取 $0 < \alpha_m < \alpha_M$ 使得

$$\alpha_m \leq \alpha_k \leq \alpha_M.$$

- BB方法本身是非单调方法, 有时也配合非单调收敛准则使用以获得更好的实际效果.

非单调线搜索的BB方法

Algorithm 非单调线搜索的BB方法

- 1: 给定 x^0 , 选取初值 $\alpha > 0$, 整数 $M \geq 0$, $c_1, \beta, \varepsilon \in (0, 1)$, $k = 0$.
 - 2: **while** $\|\nabla f(x^k)\| > \varepsilon$ **do**
 - 3: **while** $f(x^k - \alpha \nabla f(x^k)) \geq \max_{0 \leq j \leq \min(k, M)} f(x^{k-j}) - c_1 \alpha \|\nabla f(x^k)\|^2$
 do
 - 4: 令 $\alpha \leftarrow \beta \alpha$.
 - 5: **end while**
 - 6: 令 $x^{k+1} = x^k - \alpha \nabla f(x^k)$.
 - 7: 根据BB步长公式之一计算 α , 并做截断使得 $\alpha \in [\alpha_m, \alpha_M]$.
 - 8: $k \leftarrow k + 1$.
 - 9: **end while**
-

二次函数的BB 方法

- 设二次函数 $f(x,y) = x^2 + 10y^2$, 并使用BB方法进行迭代, 初始点为 $(-10, -1)$.
- BB方法的收敛速度较快, 在经历15次迭代后已经接近最优值点. 从等高线也可观察到BB方法是非单调方法.
- 实际上, 对于正定二次函数, BB方法有R-线性收敛速度.




Figure: 梯度法与BB 方法的前15次迭代

提纲

- 1 无约束优化问题
- 2 线搜索准则
- 3 线搜索算法
- 4 线搜索一般收敛性分析
- 5 梯度下降法
- 6 Barzilar-Borwein 方法
- 7 应用举例

LASSO问题求解

$$\min f(x) = \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1.$$

- LASSO 问题的目标函数 $f(x)$ 不光滑, 在某些点处无法求出梯度, 因此不能直接对原始问题使用梯度法求解
- 不光滑项为 $\|x\|_1$, 它实际上是 x 各个分量绝对值的和, 考虑如下一维光滑函数:

$$l_\delta(x) = \begin{cases} \frac{1}{2\delta} x^2, & |x| < \delta, \\ |x| - \frac{\delta}{2}, & \text{其他.} \end{cases}$$

- 上述定义实际上是Huber 损失函数的一种变形, 当 $\delta \rightarrow 0$ 时, 光滑函数 $l_\delta(x)$ 和绝对值函数 $|x|$ 会越来越接近.

Huber损失函数是一种平滑的损失函数，通常用于回归问题。相比于均方误差（Mean Squared Error, MSE）损失函数，Huber损失对异常值（outliers）的敏感性较小，因为它在接近零的区域是二次的，而在远离零的区域是线性的。这种性质使得Huber损失在一些实际问题中更为鲁棒，能够更好地处理数据中的噪声和异常值。

Huber损失函数的定义如下：

$$L_{\delta}(y, f(x)) = \begin{cases} \frac{1}{2}(y - f(x))^2, & \text{for } |y - f(x)| \leq \delta \\ \delta(|y - f(x)| - \frac{1}{2}\delta), & \text{otherwise} \end{cases}$$

其中， y 是观测到的真实标签， $f(x)$ 是模型的预测值， δ 是一个阈值参数。在这个定义中，当 $|y - f(x)| \leq \delta$ 时，Huber损失就是均方误差；而当 $|y - f(x)| > \delta$ 时，Huber损失切换为线性损失，使其对较大的残差更为鲁棒。Huber损失的形状在接近零的区域更为平滑，对于离群值的影响较小，这使得它在一些实际问题中表现得比均方误差更好。在某些优化问题中，Huber损失的使用可以使得模型更加稳健，减少异常值对模型参数估计的影响。

LASSO问题求解

光滑化LASSO 问题为

$$\min f_{\delta}(x) = \frac{1}{2}\|Ax - b\|^2 + \mu L_{\delta}(x), \quad \text{其中} \quad L_{\delta}(x) = \sum_{i=1}^n l_{\delta}(x_i),$$

δ 为给定的光滑化参数.




Figure: 当 δ 取不同值时 $l_{\delta}(x)$ 的图形

LASSO问题求解

- $f_\delta(x)$ 的梯度为

$$\nabla f_\delta(x) = A^T(Ax - b) + \mu \nabla L_\delta(x),$$

其中 $\nabla L_\delta(x)$ 是逐个分量定义的：

$$(\nabla L_\delta(x))_i = \begin{cases} \text{sign}(x_i), & |x_i| > \delta, \\ \frac{x_i}{\delta}, & |x_i| \leq \delta. \end{cases}$$

- $f_\delta(x)$ 的梯度是利普希茨连续的, 且相应常数为 $L = \|A^T A\|_2 + \frac{\mu}{\delta}$.
- 根据梯度法在凸函数上的收敛性定理, 固定步长需不超过 $\frac{1}{L}$ 才能保证算法收敛, 如果 δ 过小, 那么我们需要选取充分小的步长 α_k 使得梯度法收敛.

LASSO问题求解






Figure: 光滑化LASSO 问题求解迭代过程

LASSO问题求解



(a) 精确解



(b) 梯度法解

Figure: 光滑化LASSO 问题求解结果

Tikhonov 正则化模型求解

- x 表示真实图像, 它是一个 $m \times n$ 点阵, 用 y 来表示带噪声图像

$$y = x + e,$$

其中 e 是高斯白噪声.

- 为了从有噪声的图像 y 中还原出原始图像 x , 利用 Tikhonov 正则化的思想可以建立如下模型:

$$\min_x f(x) = \frac{1}{2} \|x - y\|_F^2 + \lambda (\|D_1 x\|_F^2 + \|D_2 x\|_F^2),$$

其中 $D_1 x, D_2 x$ 分别表示对 x 在水平方向和竖直方向上做向前差分,

$$(D_1 x)_{ij} = \frac{1}{h} (x_{i+1,j} - x_{ij}), \quad (D_2 x)_{ij} = \frac{1}{h} (x_{i,j+1} - x_{ij}),$$

其中 h 为给定的离散间隔.

Tikhonov 正则化模型求解

- Tikhonov 正则化模型由两项组成:

- ① 第一项为保真项, 即要求真实图像 x 和带噪声的图像 y 不要相差太大, 这里使用 F 范数的原因是我们假设噪声是高斯白噪声;
- ② 第二项为Tikhonov 正则项, 它实际上是对 x 本身的性质做出限制, 在这里的含义是希望原始图像 x 各个部分的变化不要太剧烈(即水平和竖直方向上差分的平方和不要太大), 这种正则项会使得恢复出的 x 有比较好的光滑性.

- 模型的目标函数是光滑的, 因此可以利用梯度法来求解:

$$\nabla f(x) = x - y - 2\lambda\Delta x,$$

其中 Δ 是图像 x 的离散拉普拉斯算子, 即

$$(\Delta x)_{ij} = \frac{x_{i+1,j} + x_{i-1,j} + x_{i,j+1} + x_{i,j-1} - 4x_{ij}}{h^2},$$

- 因此梯度法的迭代格式为

$$x^{k+1} = x^k - t(I - 2\lambda\Delta)x^k + ty^k.$$

Tikhonov 正则化模型求解结果



(a) 原图



(b) 高斯噪声



(c) $\lambda = 0.5$



(d) $\lambda = 2$

Figure: Tikhonov 正则化模型求解结果

从图可以看出，Tikhonov 正则化模型能够有效去除图像中噪声，但是它也有缺点：经过Tikhonov 正则化的图像会偏光滑，原图中物体之间的边界变成很模糊，当 λ 较大时有位明显。这是由于模型正则化选择不当，后续章节考虑取其他正则化项的求解。