

- 对于问题(??), 令 $t = \|Ax - b\|_\infty$, 则得到等价问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n, t \in \mathbb{R}} \quad & t, \\ \text{s.t.} \quad & \|Ax - b\|_\infty \leq t. \end{aligned}$$

- 利用 ℓ_∞ 范数的定义, 可以进一步写为

$$\begin{aligned} \min_{x \in \mathbb{R}^n, t \in \mathbb{R}} \quad & t, \\ \text{s.t.} \quad & -t\mathbf{1} \leq Ax - b \leq t\mathbf{1}, \end{aligned}$$

这是一个线性规划问题.


二次规划问题 (Quadratic Programming, QP)

$$\min f(x_1, x_2) = x_1^2 + 2x_2^2 - 2x_1x_2 + 2x_1 - 6x_2$$

$$x_1 + x_2 \geq 2$$

$$\text{s.t. } x_1 - 2x_2 \leq 4$$


$$2x_1 + x_2 = 6$$



二次规划问题 (Quadratic Programming, QP)

$$\begin{aligned} \min \quad & \frac{1}{2}x^T Px + q^T x + r \\ \text{s.t.} \quad & Gx \leq h \\ & Ax = b \end{aligned} \tag{1}$$

- $P \in \mathcal{S}_+^n$, 故目标函数是二次的
- 在一个多面体内最小化一个二次凸问题



二次规划的应用

- 最小二乘问题：

$$\min \|Ax - b\|_2^2 \quad (2)$$

- 该问题的解析解为 $x^* = A^\dagger b$ (其中 A^\dagger 为广义逆)
- 随机线性规划

$$\begin{aligned} \min \quad & \bar{c}^T x + \gamma x^T \Sigma x = \mathbf{E} c^T x + \gamma \text{var}(c^T x) \\ \text{s.t.} \quad & Gx \leq h, \quad Ax = b \end{aligned}$$

- c 是随机向量并且均值为 \bar{c} , 方差为 Σ
- $c^T x$ 均值为 $\bar{c}^T x$, 方差为 $x^T \Sigma x$
- $\gamma > 0$ 为风险参数, 控制预期成本与风险.

带有二次约束的二次规划问题(QCQP)

考虑带有二次约束的二次规划问题：

$$\begin{array}{ll}\min & (1/2)x^T P_0 x + q_0^T x + r_0 \\ \text{s.t.} & (1/2)x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \dots, m \\ & Ax = b\end{array}$$

- $P_i \in \mathbb{S}_+^n$; 即目标函数与约束均为二次凸的
- 如果 $P_1, \dots, P_m \in \mathbb{S}_{++}^n$, 则可行域为 m 个椭球与一个仿射集的交集.

广义不等式约束

- 凸问题的广义不等式约束

$$\begin{array}{ll}\min & f_0(x) \\ \text{s.t.} & f_i(x) \preceq_{K_i} 0, \quad i = 1, \dots, m \\ & Ax = b\end{array}$$

- $f_0 : \mathbb{R}^n \rightarrow \mathbb{R}$ 为凸函数; $f_i : \mathbb{R}^n \rightarrow \mathbb{R}^{k_i}$ 关于适当锥 K_i 为 K_i -凸的.
 - 与标准凸问题有相同的性质
- 锥形式问题(具有仿射目标函数与约束的特殊情况)

$$\begin{array}{ll}\min & c^T x \\ \text{s.t.} & Fx + g \preceq_K 0 \\ & Ax = b\end{array}$$

将线性规划问题延伸到了非多面体锥上($K = \mathbb{R}_+^m$)

QP问题的例子

- Least-squares and regression
- Distance between polyhedra

Least-squares and regression

- 问题描述

$$\begin{aligned} \text{minimize} \quad & \|Ax - b\|_2^2 \\ \|Ax - b\|_2^2 = & x^T A^T A x - 2b^T A x + b^T b \end{aligned}$$

具有解析解 $x = A^\dagger b$, A^\dagger 是 A 的伪逆

多面体间距离

- 问题描述： R^n 上多面体

$P_1 = \{x \mid A_1x \preceq b_1\}$ 和 $P_2 = \{x \mid A_2x \preceq b_2\}$ 的（Euclid）距离定义为

$$\text{dist}(P_1, P_2) = \inf \{\|x_1 - x_2\| \mid x_1 \in P_1, x_2 \in P_2\}$$

$$P_1 = \{x \mid A_1x \preceq b_1\} \quad P_2 = \{x \mid A_2x \preceq b_2\}$$

- QP形式

$$\begin{aligned} & \text{minimize} \quad \|x_1 - x_2\|_2^2 \\ & \text{subject to} \quad A_1x \preceq b_1, A_2x \preceq b_2 \end{aligned}$$

这一问题无可行解的充要条件是，其中一个多面体是空的。其最优解为零的充要条件是，多面体相交，这种情况下，最优的 x_1 和 x_2 是相等的（并且是交集 $P_1 \cap P_2$ 中的点）。否则最优的 x_1 和 x_2 分别在 P_1 和 P_2 中，并且是最接近的。（我们将在第8章中更加详细地讨论涉及距离的几何问题。）

二阶锥规划 (Second-order cone program, SOCP)

- SOCP问题的基本描述：

$$\begin{aligned} & \text{minimize} && f^T x \\ & \text{subject to} && \|A_i x + b\|_2 \leq c_i^T x + d_i, i = 1, \dots, m \\ & && Fx = g, \end{aligned}$$

- 二次锥约束条件：

$$\|Ax + b\|_2 \leq c^T x + d$$

当 $c_i = 0, i = 1, \dots, m$, SOCP 等同于 QCQP;
 $A_i = 0, i = 1, \dots, m$, SOCP 退化为线性规划。

SOCP问题的例 – Robust linear programming

- 问题描述：

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & a_i^T x \leq b_i\end{array}$$

其中参数 c, a_i 和 b_i 含有一些不确定性或变化。

- 例 c, b_i 为确定的常数， a_i 为变量，其范围满足：

$$a_i \in \varepsilon_i = \{\bar{a}_i + P_i u \mid \|u\|_2 \leq 1\}$$

- SOCP形式

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & \bar{a}_i^T x + \|P_i^T x\|_2 \leq b_i\end{array}$$

几何规划(Geometric Programming, GP)

- 几何规划的基本描述：

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 1, i = 1, \dots, m \\ & && h_i(x) = 1, i = 1, \dots, p \end{aligned}$$

其中 f_i 为正项式， h_i 为单项式， $D = R_{++}^n$ 。

- 单项式与正项式($c > 0, c_k > 0, \dots$)：

$$\begin{aligned} f(x) &= cx_1^{a_1} \cdots x_n^{a_n} \\ f(x) &= \sum_{k=1}^K c_k x_1^{a_{1k}} \cdots x_n^{a_{nk}} \end{aligned}$$

- 正项式对于加法，数乘和非负的伸缩变化是封闭的。
- 单项式对于数乘和除是封闭的。
- 一个正项式和一个单项式相乘，其结果为一个正项式。
- 一个正项式除以一个单项式，其结果仍为正项式。

凸形式的几何规划

几何规划（一般）不是凸优化问题，但是通过变量代换以及目标、约束函数的转化，GP问题可以转化为凸优化问题。

- 令：

$$y_i = \log x_i$$

- 几何规划的凸形式：

$$\begin{aligned} \text{minimize} \quad & \tilde{f}_0(y) = \log \left(\sum_{k=1}^{K_0} e^{a_{0k}^T y + b_{0k}} \right) \\ \text{subject to} \quad & \tilde{f}_i(y) = \log \left(\sum_{k=1}^{K_i} e^{a_{ik}^T y + b_{ik}} \right) \leq 0, i = 1, \dots, m \\ & \tilde{h}_i(y) = g_i^T y + h_i = 0, i = 1, \dots, p \end{aligned}$$

广义不等式约束

- 广义不等式约束的优化问题：

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \preceq_{K_i} 0, i = 1, \dots, m \\ & && Ax = b \end{aligned}$$

- SOCP的描述：

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && - (A_i x + b_i, c_i^T x + d_i) \preceq_{K_i} 0, i = 1, \dots, m \\ & && Fx = g \\ & && K_i = \{ (y, t) \in R^{k_i+1} \mid \|y\|_2 \leq t \} \end{aligned}$$

半定规划

半定规划问题的一般形式如下：

$$\begin{aligned} \min \quad & c^T x, \\ \text{s.t.} \quad & x_1 A_1 + x_2 A_2 + \cdots + x_n A_n + B \preceq 0, \\ & Gx = h, \end{aligned} \tag{3}$$

其中 $c \in \mathbb{R}^n$, $A_i \in \mathcal{S}^m$, $i = 1, 2, \dots, m$, $B \in \mathcal{S}^m$, $G \in \mathbb{R}^{p \times n}$, $h \in \mathbb{R}^p$ 为已知的向量和矩阵, $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ 是自变量.

- 半定规划 (SDP) 是线性规划在矩阵空间中的一种推广. 它的目标函数和等式约束均为关于矩阵的线性函数, 而它与线性规划不同的地方是其自变量取值于半正定矩阵空间.
- 作为一种特殊的矩阵优化问题, 半定规划在某些结构上和线性规划非常相似, 很多研究线性规划的方法都可以作为研究半定规划的基础.

半定规划

类似于线性规划问题，我们考虑半定规划的标准形式

$$\begin{aligned} \min \quad & \langle C, X \rangle, \\ \text{s.t.} \quad & \langle A_1, X \rangle = b_1, \\ & \dots \\ & \langle A_m, X \rangle = b_m, \\ & X \succeq 0, \end{aligned} \tag{4}$$

和对偶形式：

$$\begin{aligned} \min \quad & -b^T y, \\ \text{s.t.} \quad & y_1 A_1 + y_2 A_2 + \dots + y_n A_n \preceq C. \end{aligned} \tag{5}$$

形如(3)式的优化问题都可以转化成(4)式或者(5)式的形式。

LP, SOCP 与 SDP 的比较

LP 与 SDP

$$\begin{array}{ll}\text{LP:} & \min \quad c^T x \\ & \text{s.t.} \quad Ax \leq b\end{array}$$

$$\begin{array}{ll}\text{SDP:} & \min \quad c^T x \\ & \text{s.t.} \quad \text{diag}(Ax - b) \preceq 0\end{array}$$

SOCP 与 SDP

$$\begin{array}{ll}\text{SOCP:} & \min \quad f^T x \\ & \text{s.t.} \quad \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m\end{array}$$

$$\begin{array}{ll}\text{SDP:} & \min \quad f^T x \\ & \text{s.t.} \quad \begin{bmatrix} (c_i^T x + d_i)I & A_i x + b_i \\ (A_i x + b_i)^T & c_i^T x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, m\end{array}$$

二次约束二次规划问题的半定规划松弛

- 考虑二次约束二次规划问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & x^T A_0 x + 2b_0^T x + c_0, \\ \text{s.t.} \quad & x^T A_i x + 2b_i^T x + c_i \leq 0, \quad i = 1, 2, \dots, m, \end{aligned} \quad (6)$$

其中 A_i 为 $n \times n$ 对称矩阵. 当部分 A_i 为对称不定矩阵时, 问题(6)是NP 难的非凸优化问题.

- 写出问题(6)的半定规划松弛问题. 对任意 $x \in \mathbb{R}^n$ 以及 $A \in \mathcal{S}^n$, 有恒等式

$$x^T A x = \text{Tr}(x^T A x) = \text{Tr}(A x x^T) = \langle A, x x^T \rangle,$$

因此问题(6)中所有的二次项均可用下面的方式进行等价刻画:

$$x^T A_i x + 2b_i^T x + c_i = \langle A_i, x x^T \rangle + 2b_i^T x + c_i.$$

二次约束二次规划问题的半定规划松弛

由上述分析，原始问题等价于

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \langle A_0, X \rangle + 2b_0^T x + c_0 \\ \text{s.t.} \quad & \langle A_i, X \rangle + 2b_i^T x + c_i \leq 0, \quad i = 1, 2, \dots, m, \\ & X = xx^T. \end{aligned} \tag{7}$$

进一步地，

$$\begin{aligned} x^T A_i x + 2b_i^T x + c_i &= \left\langle \begin{pmatrix} A_i & b_i \\ b_i^T & c_i \end{pmatrix}, \begin{pmatrix} X & x \\ x^T & 1 \end{pmatrix} \right\rangle, \\ &\stackrel{\text{def}}{=} \langle \overline{A}_i, \overline{X} \rangle, \quad i = 0, 1, \dots, m. \end{aligned}$$

二次约束二次规划问题的半定规划松弛

接下来将等价问题(7) 松弛为半定规划问题.

- 在问题(7) 中, 唯一的非线性部分是约束 $X = xx^T$, 我们将其松弛成半正定约束 $X \succeq xx^T$. 可以证明, $\bar{X} \succeq 0$ 与 $X \succeq xx^T$ 是等价的.
- 因此这个问题的半定规划松弛可以写成

$$\begin{aligned} \min \quad & \langle \bar{A}_0, \bar{X} \rangle \\ \text{s.t.} \quad & \langle \bar{A}_i, \bar{X} \rangle \leq 0, \quad i = 1, 2, \dots, m, \\ & \bar{X} \succeq 0, \\ & \bar{X}_{n+1, n+1} = 1. \end{aligned}$$

其中“松弛”来源于我们将 $X = xx^T$ 替换成了 $X \succeq xx^T$.

最大割问题的半定规划松弛

- 令 G 为一个无向图，其节点集合为 $V = \{1, 2, \dots, n\}$ 和边的集合为 E 。令 $w_{ij} = w_{ji}$ 为边 $(i, j) \in E$ 上的权重，并假设 $w_{ij} \geq 0, (i, j) \in E$ 。最大割问题是找到节点集合 V 的一个子集 S 使得 S 与它的补集 \bar{S} 之间相连边的权重之和最大化。
- 可以将最大割问题写成如下整数规划的形式：令 $x_j = 1, j \in S$ 和 $x_j = -1, j \in \bar{S}$ ，则

$$\begin{aligned} \max \quad & \frac{1}{2} \sum_{i < j} (1 - x_i x_j) w_{ij} \\ \text{s.t.} \quad & x_j \in \{-1, 1\}, j = 1, 2, \dots, n. \end{aligned} \tag{8}$$

- 在问题(8)中，只有当 x_i 与 x_j 不同时，目标函数中 w_{ij} 的系数非零。最大割问题是一个离散优化问题，很难在多项式时间内找到它的最优解。

二次约束二次规划问题的半定规划松弛

接下来介绍如何将问题(8) 松弛成一个半定规划问题.

- 令 $W = (w_{ij}) \in \mathcal{S}^n$, 并定义 $C = -\frac{1}{4}(\text{Diag}(W\mathbf{1}) - W)$ 为图 G 的拉普拉斯矩阵的 $-\frac{1}{4}$ 倍, 则问题(8) 可以等价地写为

$$\begin{aligned} \min \quad & x^T C x, \\ \text{s.t.} \quad & x_i^2 = 1, \quad i = 1, 2, \dots, n. \end{aligned}$$

由于目标函数是关于 x 的二次函数, 可将其等价替换为 $\langle C, xx^T \rangle$.

- 接下来令 $X = xx^T$, 注意到约束 $x_i^2 = 1$, 这意味着矩阵 X 对角线元素 $X_{ii} = 1$. 因此利用矩阵形式我们将最大割问题转化为

$$\begin{aligned} \min \quad & \langle C, X \rangle, \\ \text{s.t.} \quad & X_{ii} = 1, \quad i = 1, 2, \dots, n, \\ & X \succeq 0, \quad \text{rank}(X) = 1. \end{aligned} \tag{9}$$

- 问题(9) 和(8) 是等价的, 这是因为 $X = xx^T$ 可以用约束 $X \succeq 0$ 和 $\text{rank}(X) = 1$ 等价刻画.

半正定规划

- SDP问题描述：

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && x_1 F_1 + x_2 F_2 + \cdots + x_n F_n + G \preceq 0 \\ & && Ax = b \end{aligned}$$

其中 $F_i, G \in \mathbf{S}^k$ 。

- 不等式约束包含多个线性矩阵不等式（LMI）：

$$x_1 \hat{F}_1 + \cdots + x_n \hat{F}_n + \hat{G} \preceq 0, \quad x_1 \tilde{F}_1 + \cdots + x_n \tilde{F}_n + \tilde{G} \preceq 0$$

等价于单个LMI：

$$x_1 \begin{bmatrix} \hat{F}_1 & 0 \\ 0 & \tilde{F}_1 \end{bmatrix} + x_2 \begin{bmatrix} \hat{F}_2 & 0 \\ 0 & \tilde{F}_2 \end{bmatrix} + \cdots + x_n \begin{bmatrix} \hat{F}_n & 0 \\ 0 & \tilde{F}_n \end{bmatrix} + \begin{bmatrix} \hat{G} & 0 \\ 0 & \tilde{G} \end{bmatrix} \preceq 0$$

半定规划

- LP与等价的SDP:

$$\begin{aligned} \text{LP : minimize} \quad & c^T x \\ \text{subject to} \quad & Ax \preceq b \end{aligned}$$

$$\begin{aligned} \text{SDP : minimize} \quad & c^T x \\ \text{subject to} \quad & \text{diag}(Ax - b) \preceq 0 \end{aligned}$$

- SOCP与等价的SDP:

$$\begin{aligned} \text{SOCP : minimize} \quad & f^T x \\ \text{subject to} \quad & \|A_i x + b_i\|_2 \leq c_i^T x + d_i, \quad i = 1, \dots, m \end{aligned}$$

$$\begin{aligned} \text{SDP : minimize} \quad & f^T x \\ \text{subject to} \quad & \begin{bmatrix} (c_i^T x + d_i) I & A_i x + b_i \\ (A_i x + b_i)^T & c_i^T x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, m \end{aligned}$$

特征值最小化

- 特征值最小化：

$$\text{minimize} \quad \lambda_{\max}(A(x))$$

给定 $A_i \in \mathbf{S}^k$, $A(x) = A_0 + x_1 A_1 + \cdots + x_n A_n$ 。

- 等价SDP：

$$\begin{aligned} &\text{minimize} \quad t \\ &\text{subject to} \quad A(x) \preceq tI \end{aligned}$$

其中 $x \in \mathbf{R}^n, t \in \mathbf{R}$ 。

$$\lambda_{\max}(A) \leq t \iff A \preceq tI$$

第5章 对偶问题

优化问题的拉格朗日函数

- 设优化问题：

$$\begin{aligned} & \text{minimize} && f_0(x), \quad x \in \mathcal{R}^n \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m \\ & && h_i(x) = 0, \quad j = 1, \dots, p \end{aligned}$$

- 拉格朗日函数 $L : D \times R^n \times R^p \rightarrow R$:

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$

- 对固定的 x , 拉格朗日函数 $L(x, \lambda, \nu)$ 为关于 λ 和 ν 的仿射函数。

拉格朗日对偶函数

- 拉格朗日对偶函数(lagrange dual function) :

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu) = \inf_{x \in D} (f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x))$$

若拉格朗日函数没有下界, 则令

$$g(\lambda, \nu) = -\infty$$

- 拉格朗日对偶函数为凹函数。
- 对 $\forall \lambda \succeq 0$ 和 $\forall \nu$, 若原最优化问题有最优值 p^* , 则

$$g(\lambda, \nu) \leq p^*$$

对偶函数的例子

- 线性方程的最小二乘解
- 标准形式的线性规划问题
- 双向划分问题

线性方程的最小二乘解

- 原问题：

$$\begin{array}{ll}\text{minimize} & x^T x, x \in \mathcal{R}^n \\ \text{subject to} & Ax = b\end{array}$$

- 拉格朗日函数：

$$L(x, v) = x^T x + v^T (Ax - b)$$

- 拉格朗日对偶函数：

$$g(v) = -\frac{1}{4}v^T AA^T v - b^T v$$

$g(v)$ 是一个二次凹函数，定义域为 R^p 。利用对偶函数给出原问题下界的性质，从而对于任意的 $v \in R^p$ ，有 $-\frac{1}{4}v^T AA^T v - b^T v \leq \inf \{x^T x | Ax = b\}$

标准形式的线性规划问题

- 原问题：

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && Ax = b \\ & && x \succeq 0 \end{aligned}$$

- 拉格朗日函数：

$$\begin{aligned} L(x, \lambda, v) &= c^T x - \lambda^T x + v^T (Ax - b) \\ &= -v^T b + (c - \lambda + A^T v)^T x \end{aligned}$$

- 拉格朗日对偶函数：

$$g(\lambda, v) = \begin{cases} -b^T v & A^T v - \lambda + c = 0 \\ -\infty & \text{其他情况} \end{cases}$$

注：对偶函数 g 只有在 $R^m \times R^p$ 上的一个正常方式仿射子集上取值有限。

双向划分问题

- 原问题：

$$\begin{aligned} & \text{minimize} && x^T W x, W \in S^n \\ & \text{subject to} && x_i^2 = 1, i = 1, \dots, n \end{aligned}$$

- 拉格朗日函数：

$$\begin{aligned} L(x, v) &= x^T W x + \sum_i^n v_i (x_i^2 - 1) \\ &= x^T (W + \text{diag}(v)) x - \mathbf{1}^T v \end{aligned}$$

- 拉格朗日对偶函数：

$$g(v) = \begin{cases} -\mathbf{1}^T v & W + \text{diag}(v) \succeq 0 \\ -\infty & \text{otherwise} \end{cases}$$

- 弱对偶性: $p^* \geq -\mathbf{1}^T \nu$ 若 $W + \text{diag}(\nu) \succeq 0$

- 取 $\nu = -\lambda_{\min}(W)\mathbf{1}$ 得最优解 p^* 的一个下界的估计, $p^* \geq n\lambda_{\min}(W)$

对偶函数与共轭函数

- 共轭函数

$$f^*(y) = \sup_{x \in \text{dom} f} (y^T x - f(x))$$

- 共轭函数与对偶函数存在密切联系
- 具有线性不等式约束和线性等式约束的优化问题：

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && Ax \preceq b, Cx = d \end{aligned}$$

对偶函数：

$$\begin{aligned} g(\lambda, v) &= -b^T \lambda - d^T v - f_0^*(-A^T \lambda - C^T v) \\ \text{dom} g &= \{(\lambda, v) \mid -A^T \lambda - C^T v \in \text{dom} f_0^*\} \end{aligned}$$

实例:等式约束下的范数最小化

$$\begin{aligned} \min \quad & \|x\| \\ \text{s.t.} \quad & Ax = b \end{aligned}$$

对偶函数

$$g(\nu) = \inf_x (\|x\| - \nu^T Ax + b^T \nu) = \begin{cases} b^T \nu & \|A^T \nu\|_* \leq 1 \\ -\infty & \text{其他} \end{cases}$$

其中 $\|v\|_* = \sup_{\|u\| \leq 1} u^T v$ 是 $\|\cdot\|$ 的对偶范数

证明: 利用 $\inf_x (\|x\| - y^T x)$ 在 $\|y\|_* \leq 1$ 时等于0 否则等于 $-\infty$

- 若 $\|y\|_* \leq 1$, 则 $\|x\| - y^T x \geq 0$ 对任意 x 都成立, 当 $x = 0$ 时取等
- 若 $\|y\|_* > 1$, 取 $x = tu$, 其中 $\|u\| \leq 1, u^T y = \|y\|_* > 1$:

$$\|x\| - y^T x = t(\|u\| - \|y\|_*) \rightarrow -\infty \text{ 当 } t \rightarrow \infty$$

弱对偶性: $p^* \geq b^T \nu$ 若 $\|A^T \nu\|_* \leq 1$

熵的最大化

- 原始问题:

$$\begin{aligned} & \text{minimize} && \sum_{i=1}^n x_i \log x_i, && D = R_+^n \\ & \text{subject to} && Ax \preceq b, 1^T x = 1 \end{aligned}$$

- 共轭函数:

$$f_0^*(y) = \sum_{i=1}^n e^{y_i - 1}$$

- 对偶函数:

$$\begin{aligned} g(\lambda, v) &= -b^T \lambda - v - f_0^*(-A^T \lambda - 1v) \\ &= -b^T \lambda - v - \sum_{i=1}^m e^{-a_i^T \lambda - v - 1} \\ &= -b^T \lambda - v - e^{-v-1} \sum_{i=1}^m e^{-a_i^T \lambda} \end{aligned}$$

最小体积覆盖椭圆

- 原始问题：

$$\begin{aligned} & \text{minimize} && \log \det X^{-1}, \quad D = S_{++}^n \\ & \text{subject to} && a_i^T X a_i \leq 1, i = 1, \dots, m \end{aligned}$$

- 共轭函数：

$$f_0^*(Y) = \log \det(-Y)^{-1} - n$$

- 对偶函数：

$$g(\lambda) = \begin{cases} \log \det (\sum_{i=1}^m \lambda_i a_i a_i^T) - 1^T \lambda + n & \sum_{i=1}^m \lambda_i a_i a_i^T \succ 0 \\ -\infty & \text{otherwise} \end{cases}$$

拉格朗日对偶问题

- 拉格朗日对偶问题的描述：

$$\begin{array}{ll}\text{maximize} & g(\lambda, v) \\ \text{subject to} & \lambda \succeq 0\end{array}$$

- 对偶可行域

$$\begin{array}{l}\lambda \succeq 0 \\ g(\lambda, v) > -\infty\end{array}$$

- 最优值

$$d^*$$

- 最优解

$$(\lambda^*, v^*)$$

LP问题的对偶问题

- 标准LP问题

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & Ax = b, x \succeq 0\end{array}$$

- 对偶函数

$$g(\lambda, v) = \begin{cases} -b^T v & A^T v - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}$$

- 对偶问题

$$\begin{array}{ll}\text{maximize} & g(\lambda, v) \\ \text{subject to} & \lambda \succeq 0\end{array}$$

- 等价描述

$$\begin{array}{ll}\text{maximize} & g(\lambda, v) \\ \text{subject to} & A^T v - \lambda + c = 0, \lambda \succeq 0\end{array}$$

LP问题的对偶问题

- 标准LP问题

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & Ax = b \\ & x \succeq 0\end{array}$$

- 对偶函数

$$g(\lambda, \nu) = \begin{cases} -b^T \nu & A^T \nu - \lambda + c = 0 \\ -\infty & \text{otherwise} \end{cases}$$

- 对偶问题

$$\begin{array}{ll}\text{maximize} & g(\lambda, \nu) \\ \text{subject to} & \lambda \succeq 0\end{array}$$

- 等价描述

$$\begin{array}{ll}\text{maximize} & g(\lambda, \nu) \\ \text{subject to} & A^T \nu - \lambda + c = 0 \\ & \lambda \succeq 0\end{array}$$

弱对偶性

定理

弱对偶性：设原始问题的最优值为 p^* ,对偶问题的最优值为 d^* ,则 $d^* \leq p^*$ 成立。

- 最优对偶间隙：optimal duality gap

$$p^* - d^*$$

- 可以利用对偶问题找到原始问题最优解的下界。

强对偶性

定义

强对偶性 设原始问题的最优值为 p^* ,对偶问题的最优值为 d^* 。
若 $d^* = p^*$ 成立, 则称原始问题和对偶问题之间具有强对偶性。

- 强对偶性并不是总是成立的。
- 凸优化问题通常（但并不总是）具有强对偶性。

定理

Slater定理: 若凸优化问题存在严格可行解, 即存在 $x \in \text{relint } D$, 满足

$$\begin{aligned} f_i(x) &< 0, i = 1, \dots, m, \\ Ax &= b \end{aligned}$$

则优化问题具有强对偶性。该条件称为**Slater**条件。

Slater约束品性与强对偶原理

定理

若凸优化问题满足Slater条件, 则强对偶原理成立.

- 当 $d^* > -\infty$ 时, 对偶问题的最优解可以取到, 即存在对偶可行解 (λ^*, ν^*) , 满足 $g(\lambda^*, \nu^*) = d^* = p^*$.
- 假设集合 \mathcal{D} 内部非空(即 $\text{relint}\mathcal{D} = \mathcal{D}$), A 行满秩(否则可以去掉多余的线性等式约束)以及原始问题最优函数值 p^* 有限.
- 定义集合

$$\begin{aligned}\mathbb{A} &= \{(u, v, t) \mid \exists x \in \mathcal{D}, c_i(x) \leq u_i, i = 1, 2, \dots, m, \\ &\quad Ax - b = v, f(x) \leq t\}.\end{aligned}$$
$$\mathbb{B} = \{(0, 0, s) \in \mathbb{R}^m \times \mathbb{R}^p \times \mathbb{R} \mid s < p^*\}.$$

- 可以证明集合 \mathbb{A} 和 \mathbb{B} 是不相交的.
- 假设 $(u, v, t) \in \mathbb{A} \cap \mathbb{B}$. 根据 $(u, v, t) \in \mathbb{B}$, 有 $u = 0, v = 0$ 和 $t < p^*$.
- 由 $(u, v, t) \in \mathbb{A}$, 可知 $f(x) \leq t < p^*$, 这与 p^* 是原始问题最优值矛盾.

Slater约束品性与强对偶原理




Figure: 集合 \mathbb{A} 和 \mathbb{B} 在 $u-t$ 方向投影的示意图
(\mathbb{A} 一般为有内点的凸集, \mathbb{B} 是一条射线且不含点 $(0, 0, p^*)$)

因为 \mathbb{A} 和 \mathbb{B} 均为凸集, 由超平面分离定理, 存在 $(\lambda, \nu, \mu) \neq 0$ 和 α , 使得

$$\lambda^T u + \nu^T v + \mu t \geq \alpha, \quad \forall (u, v, t) \in \mathbb{A},$$

$$\lambda^T u + \nu^T v + \mu t \leq \alpha, \quad \forall (u, v, t) \in \mathbb{B}.$$

Slater约束品性与强对偶原理

- 我们断言 $\lambda \geq 0$ 和 $\mu \geq 0$ (否则可以取 u_i 和 t 为任意大的正实数以及 $\nu = 0$, 这会导致 $\lambda^T u + \mu t$ 在集合 \mathbb{A} 上无下界).
- 同时, 由于 $\mu t \leq \alpha$ 对于所有 $t < p^*$ 成立, 可得 $\mu p^* \leq \alpha$.
- 对任意 $x \in \mathcal{D}$, 取 $(u, \nu, t) = (c_i(x), Ax - b, f(x)) \in \mathbb{A}$, 可知

$$\sum_{i=1}^m \lambda_i c_i(x) + \nu^T (Ax - b) + \mu f(x) \geq \alpha \geq \mu p^*.$$

- 假设 $\mu > 0$, 则

$$L(x, \frac{\lambda}{\mu}, \frac{\nu}{\mu}) \geq p^*.$$

进一步地, 我们有 $g(\frac{\lambda}{\mu}, \frac{\nu}{\mu}) \geq p^*$, 根据弱对偶性 $g(\frac{\lambda}{\mu}, \frac{\nu}{\mu}) \leq p^*$ 自然成立. 因此, 必有 $g(\frac{\lambda}{\mu}, \frac{\nu}{\mu}) = p^*$ 成立. 说明在此情况下强对偶性满足, 且对偶最优解可以达到.

Slater约束品性与强对偶原理

- 考虑 $\mu = 0$ 的情况, 可以从上面得到对于所有的 $x \in \mathcal{D}$,

$$\sum_{i=1}^m \lambda_i c_i(x) + \nu^T(Ax - b) \geq 0.$$

- 取满足Slater条件的点 x_S , 有 $\sum_{i=1}^m \lambda_i c_i(x_S) \geq 0$.
- 又 $c_i(x_S) < 0$ 和 $\lambda_i \geq 0$, 我们得到 $\lambda = 0$, 上式化为

$$\nu^T(Ax - b) \geq 0, \quad \forall x \in \mathcal{D}.$$

根据 $(\lambda, \nu, \mu) \neq 0$ 可知 $\nu \neq 0$, 结合 A 行满秩可以得到 $A^T \nu \neq 0$. 由于 x_S 是可行解, 我们有 $\nu^T(Ax_S - b) = 0$.

- 因为 $x_S \in \mathcal{D}$, 则存在点 e 使得 $\tilde{x} = x_S + e \in \mathcal{D}$, 且 $\nu^T Ae = \nu^T(A\tilde{x} - b) < 0$. 这与 $\nu^T(Ax - b) \geq 0, \forall x \in \mathcal{D}$ 矛盾.
- 综上所述, Slater条件能保证强对偶性.
- 在定理的证明中, Slater条件保证了 $\mu \neq 0$.

一阶充要条件

- 对于一般的约束优化问题, 当问题满足特定约束品性时, 我们知道KKT条件是局部最优解处的必要条件.
- 而对于凸优化问题, 当Slater条件满足时, KKT条件则变为局部最优解的充要条件(根据凸性, 局部最优解也是全局最优解).

定理 (凸优化问题的一阶充要条件)

对于凸优化问题, 用 a_i 表示矩阵 A^T 的第 i 列, $\partial f, \partial c_i$ 表示次梯度, 如果Slater条件成立, 那么 x^*, λ^* 分别是原始, 对偶全局最优解当且仅当

$$\text{稳定性条件} \quad 0 \in \partial f(x^*) + \sum_{i \in \mathcal{I}} \lambda_i^* \partial c_i(x^*) + \sum_{i \in \mathcal{E}} \lambda_i^* a_i,$$

$$\text{原始可行性条件} \quad Ax^* = b, \quad \forall i \in \mathcal{E},$$

$$\text{原始可行性条件} \quad c_i(x^*) \leq 0, \quad \forall i \in \mathcal{I},$$

$$\text{对偶可行性条件} \quad \lambda_i^* \geq 0, \quad \forall i \in \mathcal{I},$$

$$\text{互补松弛条件} \quad \lambda_i^* c_i(x^*) = 0, \quad \forall i \in \mathcal{I}.$$

一阶充要条件:充分性

- 设存在 $(\bar{x}, \bar{\lambda})$ 满足KKT条件, 我们考虑凸优化问题的拉格朗日函数

$$L(x, \lambda) = f(x) + \sum_{i \in \mathcal{I}} \lambda_i c_i(x) + \sum_{i \in \mathcal{E}} \lambda_i (a_i^T x - b_i).$$

- 当固定 $\lambda = \bar{\lambda}$ 时, 注意到 $\bar{\lambda}_i \geq 0, i \in \mathcal{I}$ 以及 $\bar{\lambda}_i (a_i^T x), i \in \mathcal{E}$ 是线性函数可知 $L(x, \bar{\lambda})$ 是关于 x 的凸函数.
- 由凸函数全局最优点的一阶充要性可知, 此时 \bar{x} 就是 $L(x, \bar{\lambda})$ 的全局极小点. 根据拉格朗日对偶函数的定义,

$$L(\bar{x}, \bar{\lambda}) = \inf_{x \in \mathcal{D}} L(x, \bar{\lambda}) = g(\bar{\lambda}).$$

- 根据原始可行性条件 $A\bar{x} = b$ 以及互补松弛条件 $\bar{\lambda}_i c_i(\bar{x}) = 0, i \in \mathcal{I}$,

$$L(\bar{x}, \bar{\lambda}) = f(\bar{x}) + 0 + 0 = f(\bar{x}).$$

- 根据弱对偶原理,

$$L(\bar{x}, \bar{\lambda}) = f(\bar{x}) \geq p^* \geq d^* \geq g(\bar{\lambda}) = L(\bar{x}, \bar{\lambda}) \Rightarrow p^* = d^*,$$

故 $\bar{x}, \bar{\lambda}$ 分别是原始问题和对偶问题的最优解.

- 弱化的Slater条件：若不等式约束条件的前 k 个约束函数是仿射，则Slater条件可以弱化为：
存在 $x \in \text{relint } D$ ，满足

$$f_i(x) \leq 0, i = 1, \dots, k,$$

$$f_i(x) < 0, i = k + 1, \dots, m,$$

$$Ax = b$$

线性方程组的最小二乘解

- 原问题：

$$\begin{array}{ll}\text{minimize} & x^T x, x \in \mathcal{R}^n \\ \text{subject to} & Ax = b\end{array}$$

- 对偶问题：

$$\text{maximize} \quad g(\nu) = -\frac{1}{4}\nu^T A A^T \nu - b^T \nu$$

- 具有强对偶性

Lagrange dual of QCQP

$$\begin{array}{ll}\text{minimize} & (1/2)x^T P_0 x + q_0^T x + r_0 \\ \text{subject to} & (1/2)x^T P_i x + q_i^T x + r_i \leq 0, i = 1, \dots, m\end{array}$$

- 拉格朗日函数：

$$L(x, \lambda) = \frac{1}{2}x^T P(\lambda)x + q(\lambda)^T x + r(\lambda)$$

$$P(\lambda) = P_0 + \sum_{i=1}^m \lambda_i P_i \quad q(\lambda) = q_0 + \sum_{i=1}^m \lambda_i q_i \quad r(\lambda) = r_0 + \sum_{i=1}^m \lambda_i r_i$$

- 对偶函数：

$$g(\lambda) = \inf_x L(x, \lambda) = -\frac{1}{2}q(\lambda)^T P(\lambda)^{-1} q(\lambda) + r(\lambda)$$

Lagrange dual of QCQP

- 对偶问题：

$$\begin{aligned} & \text{maximize} && -\frac{1}{2}q(\lambda)^T P(\lambda)^{-1}q(\lambda) + r(\lambda) \\ & \text{subject to} && \lambda \succeq 0 \end{aligned}$$

- Slater条件：存在 x ，满足

$$(1/2)x^T P_i x + q_i^T x + r_i < 0, i = 1, \dots, m$$

Entropy maximization

- 原始问题：

$$\begin{aligned} & \text{minimize} && \sum_{i=1}^n x_i \log x_i, && D = R_+^n \\ & \text{subject to} && Ax \preceq b \\ & && 1^T x = 1 \end{aligned}$$

- 对偶函数：

$$g(\lambda, \nu) = -b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^T \lambda}$$

- 对偶问题：

$$\begin{aligned} & \text{maximize} && -b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-\alpha_i^T \lambda} \\ & \text{subject to} && \lambda \succeq 0 \end{aligned}$$

Entropy maximization 简化对偶问题

关于对偶变量 ν 解析求最大可以简化对偶问题(5.30)。对于任意固定 λ ，当目标函数对 ν 的导数为零时，即

$$\nu = \log \sum_{i=1}^n e^{-a_i^T \lambda} - 1.$$

目标函数取最大值。将 ν 的最优值代入对偶问题可以得到

$$\begin{aligned} \text{maximize} \quad & -b^T \lambda - \log \left(\sum_{i=1}^n e^{-a_i^T \lambda} \right) \\ \text{subject to} \quad & \lambda \succeq 0 \end{aligned}$$

这是一个非负约束的几何规划问题（凸优化问题）。弱化的Slater条件：存在 $x \succ 0$ ，满足

$$\begin{aligned} Ax &\preceq b \\ 1^T x &= 1 \end{aligned}$$

Minimum volume covering ellipsoid

- 原始问题：

$$\begin{aligned} & \text{minimize} && \log \det X^{-1}, D = S_{++}^n \\ & \text{subject to} && a_i^T X a_i \leq 1, i = 1, \dots, m \end{aligned}$$

- 对偶函数：

$$g(\lambda) = \begin{cases} \log \det \left(\sum_{i=1}^m \lambda_i a_i a_i^T \right) - 1^T \lambda + n & \sum_{i=1}^m \lambda_i a_i a_i^T \succ 0 \\ -\infty & \text{otherwise} \end{cases}$$

- 对偶问题：

$$\begin{aligned} & \text{minimize} && \log \det \left(\sum_{i=1}^m \lambda_i a_i a_i^T \right) - 1^T \lambda + n \\ & \text{subject to} && \lambda \succeq 0 \end{aligned}$$

Minimum volume covering ellipsoid

- 弱化的**Slater**条件：存在 $X \in S_{++}^n$ ，满足

$$a_i^T X a_i \leq 1, i = 1, \dots, m$$

- 弱化的**Slater**条件总成立，因此该优化问题具有强对偶性。

次优解认证和终止条件

- 对于一优化问题，若 x 为可行解， (λ, v) 为对偶问题可行解，则有如下不等式：

$$f_0(x) - p^* \leq f_0(x) - g(\lambda, v)$$

x 为 ε 次优解，其中

$$\varepsilon = f_0(x) - g(\lambda, v)$$

- 不等式可以用于对次优解的精度估计。

互补松弛条件

设 x^* 为原始优化问题的最优解, (λ^*, ν^*) 为对偶问题的最优解, 若两者具有强对偶性, 则

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, \nu^*) \\ &= \inf_x \left(f_0(x) + \sum_i \lambda_i^* f_i(x) + \sum_i \nu_i^* h_i(x) \right) \\ &\leq f_0(x^*) + \sum_i \lambda_i^* f_i(x^*) + \sum_i \nu_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

所以 $\sum_i \lambda_i^* f_i(x^*) = 0$.

即 $\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m$.

KKT优化条件

设优化问题中，函数 $f_0(x), \dots, f_m(x), h_0(x), \dots, h_p(x)$ 可微。设 x^* 为原始优化问题的最优解， (λ^*, v^*) 为对偶问题的最优解，且两者具有强对偶性，则 (x^*, λ^*, v^*) 满足如下Karush-Kuhn-Tucker(KKT)条件：

- $f_i(x^*) \leq 0, i = 1, \dots, m.$
- $h_i(x^*) = 0, i = 1, \dots, p.$
- $\lambda_i^* \geq 0, i = 1, \dots, m.$
- $\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m.$
- $\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0.$

凸优化问题的KKT条件

设原始问题为凸优化问题中，函数 $f_0(x), \dots, f_m(x), h_0(x), \dots, h_p(x)$ 可微，设 $(\tilde{x}, \tilde{\lambda}, \tilde{v})$ 满足**KKT**条件，则 \tilde{x} 为原始问题的最优解，而 $(\tilde{\lambda}, \tilde{v})$ 为对偶问题的最优解，且两者具有强对偶性。

- $f_i(\tilde{x}) \leq 0, i = 1, \dots, m.$
- $h_i(\tilde{x}) = 0, i = 1, \dots, p.$
- $\tilde{\lambda}_i \geq 0, i = 1, \dots, m$
- $\tilde{\lambda}_i f_i(\tilde{x}) = 0, i = 1, \dots, m$
- $\nabla f_0(\tilde{x}) + \sum_{i=1}^m \tilde{\lambda}_i \nabla f_i(\tilde{x}) + \sum_{i=1}^p \tilde{v}_i \nabla h_i(\tilde{x}) = 0.$

等式约束二次凸问题求极小

例5.1 等式约束凸二次最小化。我们考虑这个问题：

$$\begin{array}{ll}\text{minimize} & (1/2)x^T Px + q^T x + r \\ \text{subject to} & Ax = b,\end{array}$$

其中， $P \in \mathbf{S}_+^n$ 。这个问题的KKT条件是

$$Ax^* = b, \quad Px^* + q + A^T \nu^* = 0,$$

我们可以写成

$$\begin{bmatrix} P & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ \nu^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix} \quad (10)$$

解决了 $m+n$ 个变量的 $m+n$ 个方程。优化问题等价于方程组求解问题。

注水问题 (water-filling)

原始凸优化问题：

$$\begin{aligned} & \text{minimize} && -\sum_i \log(\alpha_i + x_i) \\ & \text{subject to} && x \succeq 0 \\ & && 1^T x = 1 \end{aligned}$$

KKT条件：

- $x^* \succeq 0, 1^T x^* = 1, \lambda^* \succeq 0,$
- $\lambda_i^* x_i^* = 0, i = 1, \dots, n,$
- $-1/(\alpha_i + x_i^*) - \lambda_i^* + v^* = 0, i = 1, \dots, n$

解得：

$$x_i^* = \begin{cases} 1/v^* - \alpha_i & v^* < 1/\alpha_i \\ 0 & v^* \geq 1/\alpha_i \end{cases}$$

其中：

凸优化问题的对偶求解

设原始优化问题与对偶问题具有强对偶性，且 (λ^*, ν^*) 为对偶问题的最优解，假设 $L(x, \lambda^*, \nu^*)$ 存在唯一的最小解，即

$$\text{minimize} \quad f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x)$$

存在唯一解 x^* 。若 x^* 为原问题的可行解，则 x^* 即为原始问题的最优解；若 x^* 不是原始问题的可行解，则原始问题不存在最优点，即原问题最优解无法达到。当对偶问题比原问题更容易求解时候，例如对偶问题可以解析求解或者有某些结构更加容易分析，上述方法有意义。

凸优化问题的对偶求解

例 5.3 熵的最大化。考虑熵的最大化问题

$$\begin{aligned} \text{minimize} \quad & f_0(x) = \sum_{i=1}^n x_i \log x_i \\ \text{subject to} \quad & Ax \preceq b \\ & \mathbf{1}^T x = 1 \end{aligned}$$

其中定义域为 \mathbf{R}_{++}^n , 其对偶问题为

$$\begin{aligned} \text{maximize} \quad & -b^T \lambda - \nu - e^{-\nu-1} \sum_{i=1}^n e^{-a_i^T \lambda} \\ \text{subject to} \quad & \lambda \succeq 0 \end{aligned}$$

(参见第 213 页以及第 220 页。) 假设 Slater 条件的弱化形式成立, 即存在 $x \succ 0$ 使得 $Ax \preceq b$ 以及 $\mathbf{1}^T x = 1$, 因此强对偶性成立, 存在一个对偶最优解 (λ^*, ν^*) 。

设对偶问题已经解出。 (λ^*, ν^*) 处的 Lagrange 函数为

$$L(x, \lambda^*, \nu^*) = \sum_{i=1}^n x_i \log x_i + \lambda^{*T} (Ax - b) + \nu^* (\mathbf{1}^T x - 1)$$

它在 \mathcal{D} 上严格凸且有下界, 因此有一个唯一解 x^* ,

$$x_i^* = 1 / \exp(a_i^T \lambda^* + \nu^* + 1), \quad i = 1, \dots, n,$$

其中 a_i 是矩阵 A 的列向量。如果 x^* 是原问题可行解, 则其必是原问题 (5.13) 的最优解。如果 x^* 不是原问题可行解, 那么我们可以说原问题的最优解不能达到。

凸优化问题的对偶求解

Example 5.4 *Minimizing a separable function subject to an equality constraint.* We consider the problem

$$\begin{array}{ll}\text{minimize} & f_0(x) = \sum_{i=1}^n f_i(x_i) \\ \text{subject to} & a^T x = b,\end{array}$$

where $a \in \mathbf{R}^n$, $b \in \mathbf{R}$, and $f_i : \mathbf{R} \rightarrow \mathbf{R}$ are differentiable and strictly convex. The objective function is called *separable* since it is a sum of functions of the individual variables x_1, \dots, x_n . We assume that the domain of f_0 intersects the constraint set, i.e., there exists a point $x_0 \in \text{dom } f_0$ with $a^T x_0 = b$. This implies the problem has a unique optimal point x^* .

The Lagrangian is

$$L(x, \nu) = \sum_{i=1}^n f_i(x_i) + \nu(a^T x - b) = -b\nu + \sum_{i=1}^n (f_i(x_i) + \nu a_i x_i),$$

which is also separable, so the dual function is

$$\begin{aligned}g(\nu) &= -b\nu + \inf_x \left(\sum_{i=1}^n (f_i(x_i) + \nu a_i x_i) \right) \\ &= -b\nu + \sum_{i=1}^n \inf_{x_i} (f_i(x_i) + \nu a_i x_i) \\ &= -b\nu - \sum_{i=1}^n f_i^*(-\nu a_i).\end{aligned}$$

The dual problem is thus

$$\text{maximize} \quad -b\nu - \sum_{i=1}^n f_i^*(-\nu a_i),$$

with (scalar) variable $\nu \in \mathbf{R}$.

Now suppose we have found an optimal dual variable ν^* . (There are several simple methods for solving a convex problem with one scalar variable, such as the bisection method.) Since each f_i is strictly convex, the function $L(x, \nu^*)$ is strictly convex in x , and so has a unique minimizer \hat{x} . But we also know that x^* minimizes $L(x, \nu^*)$, so we must have $\hat{x} = x^*$. We can recover x^* from $\nabla_x L(x, \nu^*) = 0$, i.e., by solving the equations $f'_i(x_i^*) = -\nu^* a_i$.

扰动及灵敏度分析

- 扰动问题:

$$\begin{array}{ll}\text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq u_i, \quad i = 1, \dots, m \\ & h_j(x) = v_j, \quad j = 1, \dots, p\end{array}$$

- 当 $u = 0, v = 0$ 时即为原始问题。
- 若 u_i 为正, 则第 i 个不等式约束被放宽; 若 u_i 为负, 则第 i 个不等式约束被收紧。
- 记 $p^*(u, v)$ 为扰动问题的最优解。若扰动问题无最优解, 则记

$$p^*(u, v) = \infty$$

全局不等式和局部灵敏度分析

- 设对偶问题存在最优解, 且与原始问题具有强对偶性, 若非扰动问题的最优对偶解为 (λ^*, v^*) , 则有:

$$p^*(u, v) \geq p^*(0, 0) - \lambda^{*T} u - v^{*T} v$$

- 当若 $p^*(u, v)$ 在 $u = 0, v = 0$ 处可微, 则

$$\lambda_i^* = -\frac{\partial p^*(0, 0)}{\partial u_i} \quad v_i^* = -\frac{\partial p^*(0, 0)}{\partial v_i}$$

全局不等式证明

定理

对于所有的 u 和 v ，我们有

$$p^*(u, v) \geq p^*(0, 0) - \lambda^{*T}u - \nu^{*T}v.$$

证明：假设 x 扰动问题的任一可行解，即， $f_i(x) \leq u_i$ 对 $i = 1, \dots, m$ 成立，同时 $h_i(x) = v_i$ 对 $i = 1, \dots, p$ 成立。利用强对偶性有，

$$\begin{aligned} p^*(0, 0) = g(\lambda^*, \nu^*) &\leq f_0(x) + \sum_{i=1}^m \lambda_i^* f_i(x) + \sum_{i=1}^p \nu_i^* h_i(x) \\ &\leq f_0(x) + \lambda^{*T}u + \nu^{*T}v. \end{aligned}$$

(第一个不等式利用 $g(\lambda^*, \nu^*)$ 的定义得到；第二个不等式由 $\lambda^* \succeq 0$ 得到。)因此，我们有对于扰动问题的任意可行解 x ，有下式成立

$$f_0(x) \geq p^*(0, 0) - \lambda^{*T}u - \nu^{*T}v,$$

从而全局不等式 $p^*(u, v) \geq p^*(0, 0) - \lambda^{*T}u - \nu^{*T}v$ 成立。

灵敏度分析

灵敏度解释: $p^*(u, v) \geq p^*(0, 0) - \lambda^{*T}u - v^{*T}v$




图5.10 具有一个约束 $f_1(x) \leq u$ 的凸问题的最优值 $p^*(u)$ 的图像,它是 u 的函数。当 $u = 0$ 时,对应原始未被扰动的问题;当 $u < 0$ 时,约束加强了,当 $u > 0$ 时,约束放松了。仿射函数 $p^*(0) - \lambda^*u$ 是 p^* 的一个下界。

- 如果 λ_i^* 比较大,我们加强第 i 个约束(即选择 $u_i < 0$),则最优值 $p^*(u, v)$ 必会大幅增加。
- 如果 ν_i^* 较大且大于零,我们选择 $v_i < 0$,或者如果 ν_i^* 较大且小于零,我们选择 $v_i > 0$,在这两种情况下最优值 $p^*(u, v)$ 必会大幅增加。
- 如果 λ_i^* 较小,我们放松第 i 个约束($u_i > 0$),那么最优值 $p^*(u, v)$ 不会减小太多。
- 如果 ν_i^* 较小且大于零, $v_i > 0$ 或者如果 ν_i^* 较小且小于零, $v_i < 0$,那么最优值 $p^*(u, v)$ 不会减小太多。

局部灵敏度分析

局部灵敏度: 假设 $p^*(u, v)$ 在 $(0, 0)$ 处是可微的, 然后

$$\lambda_i^* = -\frac{\partial p^*(0, 0)}{\partial u_i}, \quad \nu_i^* = -\frac{\partial p^*(0, 0)}{\partial v_i}$$

利用全局不等式结果证明(对于 λ_i^*)

$$\begin{aligned} \frac{\partial p^*(0, 0)}{\partial u_i} &= \lim_{t \searrow 0} \frac{p^*(te_i, 0) - p^*(0, 0)}{t} \geq -\lambda_i^* \\ \frac{\partial p^*(0, 0)}{\partial u_i} &= \lim_{t > 0} \frac{p^*(te_i, 0) - p^*(0, 0)}{t} \leq -\lambda_i^* \end{aligned}$$

因此 $p^*(u)$ 对于一个不等式的问题也有同样约束约束

广义不等式

本节将Lagrange 对偶理论扩展到具有广义不等式约束的问题, 即广义不等式

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \preceq_{K_i} 0, \quad i = 1, \dots, m \\ & && h_i(x) = 0, \quad i = 1, \dots, p, \end{aligned}$$

\preceq_{K_i} 是 \mathbf{R}^{k_i} 上的广义不等式对于问题(5.91) 中的每个广义不等式 $f_i(x) \preceq_{K_i} 0$, 引入Lagrange 乘子向量 $\lambda_i \in \mathbf{R}^{k_i}$ 并定义相关的Lagrange 函数如下

$$L(x, \lambda, \nu) = f_0(x) + \lambda_1^T f_1(x) + \dots + \lambda_m^T f_m(x) + \nu_1 h_1(x) + \dots + \nu_p h_p(x),$$

其中 $\lambda = (\lambda_1, \dots, \lambda_m)$, $\nu = (\nu_1, \dots, \nu_p)$ 。对偶函数的定义和原问题只有数值不等式的情形一样, 对偶函数 $g: \mathbf{R}^{k_1} \times \dots \times \mathbf{R}^{k_m} \times \mathbf{R}^p \rightarrow \mathbf{R}$, 被定义为

$$g(\lambda, \nu) = \inf_{x \in \mathcal{D}} L(x, \lambda, \nu) = \inf_{x \in \mathcal{D}} \left(f_0(x) + \sum_{i=1}^m \lambda_i^T f_i(x) + \sum_{i=1}^p \nu_i h_i(x) \right)$$

广义不等式

下界性质: 如果 $\lambda_i \succeq_{K_i^*} 0$, 同时 $g(\lambda_1, \dots, \lambda_m, \nu) \leq p^*$ 证明: 如果 \tilde{x} 是可行点, 同时 $\lambda \succeq_{K_i^*} 0$, 有

$$\begin{aligned} f_0(\tilde{x}) &\geq f_0(\tilde{x}) + \sum_{i=1}^m \lambda_i^T f_i(\tilde{x}) + \sum_{i=1}^p \nu_i h_i(\tilde{x}) \\ &\geq \inf_{x \in \mathcal{D}} L(x, \lambda_1, \dots, \lambda_m, \nu) \\ &= g(\lambda_1, \dots, \lambda_m, \nu) \end{aligned}$$

最小化所有可行点 \tilde{x} 可以得到 $p^* \geq g(\lambda_1, \dots, \lambda_m, \nu)$

Lagrange对偶优化问题为:

$$\begin{aligned} &\text{maximize} && g(\lambda_1, \dots, \lambda_m, \nu) \\ &\text{subject to} && \lambda_i \succeq_{K_i^*} 0, \quad i = 1, \dots, m \end{aligned}$$

弱对偶性总是成立, 即: $p^* \geq d^*$ 强对偶性在广义不等式的情况下同样成立: $p^* = d^*$, 前提是原问题是凸的且满足合适的约束准则

广义不等式

半定规划

primal SDP

$$\begin{aligned} & \text{minimize} && c^T x \\ & \text{subject to} && x_1 F_1 + \cdots + x_n F_n + G \preceq 0 \end{aligned}$$

- 拉格朗日乘数是矩阵 $Z \in \mathbf{S}^k$
- 拉格朗日 $L(x, Z) = c^T x + \text{tr}(Z(x_1 F_1 + \cdots + x_n F_n - G))$
- 对偶函数

$$g(Z) = \inf_x L(x, Z) = \begin{cases} -\text{tr}(GZ) & \text{tr}(F_i Z) + c_i = 0, \quad i = 1, \dots, n \\ -\infty & \text{otherwise} \end{cases}$$

对偶SDP(半定锥自对偶)

$$\begin{aligned} & \text{maximize} && -\text{tr}(GZ) \\ & \text{subject to} && Z \succeq 0, \quad \text{tr}(F_i Z) + c_i = 0, \quad i = 1, \dots, n \end{aligned}$$

如果 primal SDP 是严格可行的 ($\exists x$ with $x_1 F_1 + \cdots + x_n F_n \prec G$)

$$p^* = d^*$$